



Comparación de arquitecturas de redes neuronales para pronóstico de generación solar en el contexto colombiano

Esteban Ladino Nieto

Facultad de Ingeniería
Departamento de Ingeniería Industrial
Bogotá, Colombia
23 de febrero de 2026

Comparación de arquitecturas de redes neuronales para pronóstico de generación solar en el contexto colombiano

Esteban Ladino Nieto

Tesis presentada como requisito para optar al título de:
Ingeniero Industrial

Directora:

Dr. Alejandra Tabares Pozos
Profesora asociada - Departamento de Ingeniería Industrial
Facultad de Ingeniería
Universidad de los Andes

Agradecimientos

Agradezco en primer lugar a mi familia, y de manera muy especial a mis padres, por su apoyo incondicional, paciencia y confianza a lo largo de mi formación académica. Su ejemplo, esfuerzo y dedicación han sido el motor que me impulsa a alcanzar cada meta, incluso en los momentos más exigentes de este camino.

A mis amigos, por estar presentes en cada etapa, ofrecer palabras de ánimo, escuchar y compartir tanto los desafíos como los logros. Su compañía ha sido un apoyo emocional invaluable y un recordatorio constante de la importancia de disfrutar el proceso.

A mi asesora, la profesora Alejandra, por su guía, dedicación y valiosas recomendaciones en el desarrollo de este proyecto. Su experiencia y orientación han sido fundamentales para encaminar esta investigación hacia un enfoque sólido y pertinente y con proyección práctica. Finalmente, a la Universidad de los Andes y al Departamento de Ingeniería Industrial por brindar el espacio, las herramientas y el acompañamiento académico que han hecho posible el avance y consolidación de este trabajo.

Resumen - Abstract

El crecimiento acelerado de la generación solar en Colombia ha incrementado la necesidad de pronósticos confiables de irradiancia en horizontes de 10–60 minutos, especialmente en climas tropicales con alta variabilidad nubosa. Este trabajo compara estrategias de pronóstico basadas en modelos tabulares, satelitales e híbridos, utilizando datos de una planta fotovoltaica ubicada en El Paso (Cesar) y productos GOES-16 (DSRF y MCMIPF).

Se implementaron modelos tabulares (Regresión lineal, Random Forest, LSTM, GRU, RNN dilatada y Clockwork RNN), así como modelos satelitales ConvLSTM y arquitecturas de fusión tabular+satelital. Además, se desarrolló un pipeline reproducible en AWS para la descarga y procesamiento de parches GOES.

Los resultados muestran que el Random Forest optimizado obtiene el mejor desempeño tabular. Los modelos satelitales capturan parte de la variabilidad atmosférica, y los modelos híbridos logran mejoras sustanciales frente a los modelos puramente satelitales, aunque sin superar al mejor modelo tabular. El análisis por rangos de GHI y hora del día evidencia que las RNNs e híbridos aportan mayores beneficios en condiciones de irradiancia intermedia y horizontes de 30 – 60 minutos.

Palabras clave: pronóstico de irradiancia solar, redes neuronales recurrentes, LSTM, GRU, energía solar, transición energética, Colombia.

The rapid expansion of solar photovoltaic capacity in Colombia increases the need for reliable short-term irradiance forecasts in tropical climates characterized by highly variable cloud dynamics. This thesis compares tabular, satellite-based, and hybrid forecasting models using data from a PV plant in El Paso (Cesar) and GOES-16 products (DSRF and MCMIPF).

Tabular models (Linear Regression, Random Forest, LSTM, GRU, Dilated RNN and Clockwork RNN), ConvLSTM satellite models, and tabular+satellite fusion architectures were implemented. A reproducible AWS pipeline was built to automate the retrieval and processing of GOES image patches.

Results show that an optimized Random Forest achieves the best performance among tabular models. Satellite-only models capture meaningful cloud dynamics, and hybrid models significantly improve over pure ConvLSTM baselines, although they do not yet surpass the best tabular model. Analysis by irradiance regime and time of day indicates that recurrent and hybrid models are most beneficial in intermediate-irradiance conditions and for 30–60-minute horizons.

Keywords: solar irradiance forecasting, recurrent neural networks, LSTM, GRU, solar energy, energy transition, Colombia.

Índice general

Resumen - Abstract	4
Indice de figuras	6
Indice de tablas	7
Introducción	8
Objetivos	12
Metodología	13
Caso de estudio y fuentes de datos	13
Construcción del dataset integrado	16
Modelado de series temporales en formato tabular	17
Modelado integrando imágenes satelitales y datos tabulados	21
Resultados	24
Modelado tabular	24
Modelado híbrido tabular + satelital	31
Discusión	37
Conclusiones	41
Referencias	42
Anexos	45
Enlace a repositorio	45
Instructivo para la Descarga de Productos GOES usando AWS	45

Índice de figuras

1.	Ejemplo de imagen de disco completo de GOES-16 (producto MCMIPF) con área de interés sobre Colombia.	14
2.	Ejemplo de recorte de DSRF sobre el área de interés.	15
3.	Recorte del producto MCMIPF sobre el área de interés.	15
4.	Esquema general del flujo de construcción del <i>dataset</i> integrado.	16
5.	Esquema general de un modelo Random Forest.	18
6.	Diagrama de una celda LSTM.[17]	19
7.	Diagrama de una celda GRU.[18]	19
8.	Esquema de una RNN dilatada.[19]	20
9.	Arquitectura general de una Clockwork RNN.[20]	20
10.	Comparación de RMSE entre modelos tabulares en el conjunto de prueba.	26
11.	Ejemplos de predicción en el conjunto de prueba para Random Forest y arquitecturas recurrentes.	27
12.	Relación predicho–real para Random Forest (izq.) y GRU (der.) en el conjunto de prueba.	28
13.	RMSE segmentado según el rango de GHI real para Random Forest y GRU.	29
14.	Skill relativo a la persistencia según hora del día y horizonte para las arquitecturas recurrentes (10, 30 y 60 minutos).	30
15.	Skill medio (07:00–17:00) por horizonte de pronóstico para las cuatro arquitecturas recurrentes.	31
16.	Desempeño del modelo ConvLSTM DSRF en el conjunto de prueba (muestra larga).	32
17.	Desempeño del ConvLSTM DSRF durante dos días consecutivos del conjunto de prueba.	33
18.	Desempeño del modelo de fusión DSRF + tabular en el conjunto de prueba (muestra larga).	34
19.	Desempeño del modelo de fusión durante dos días consecutivos del conjunto de prueba.	34
20.	Error absoluto medio (MAE) segmentado por rangos de irradiancia para los modelos ConvLSTM DSRF y fusión DSRF+tabular.	35

Índice de tablas

1.	Normatividad y estándares aplicables a la energía solar en Colombia	11
2.	Desempeño de modelos tabulares en el conjunto de prueba.	25
3.	Hiperparámetros óptimos de los modelos tabulares (Optuna).	25
4.	Resumen sintético de desempeño de los modelos tabulares.	31
5.	Desempeño comparado de modelos satelitales e híbridos.	34

Introducción

La transición energética global ha impulsado la adopción acelerada de fuentes renovables como respuesta a los impactos ambientales derivados del uso intensivo de combustibles fósiles. A nivel mundial se producen cerca de 8 mil millones de toneladas métricas de carbono al año 6,5 mil millones provenientes del uso de combustibles fósiles y 1,5 mil millones de la deforestación y las proyecciones advierten consecuencias climáticas irreversibles si persiste esta tendencia [1]. Frente a este panorama, tecnologías limpias como la energía solar fotovoltaica representan una alternativa estratégica por su baja huella de carbono, disponibilidad y carácter renovable.

Colombia no es ajena a esta dinámica. El país ha impulsado la integración de energías renovables no convencionales a través de la Ley 1715 de 2014, que estableció incentivos tributarios (exenciones de IVA y aranceles, deducciones en renta) y un marco institucional liderado por el Ministerio de Minas y Energía, la UPME y la CREG. Este marco ha facilitado la expansión de proyectos fotovoltaicos, tanto de gran escala como de generación distribuida.

En los últimos años, el crecimiento ha sido notable: en 2024 ingresaron 67 nuevos proyectos de generación al SIN, 63 de ellos solares, sumando alrededor de 1,4 GW de nueva capacidad.[2] Para el primer trimestre de 2025, Colombia ya se aproxima a los 2 GW solares instalados.[3] Proyecciones de la UPME estiman que la capacidad instalada podría alcanzar del orden de 6 GW hacia 2026, en línea con las metas del “Plan 6 GW”. [4] Este crecimiento ha incrementado la participación solar en el sistema, que ha mostrado tasas superiores al 60 % anual en algunos periodos.[5]

Mercado eléctrico colombiano y necesidad de pronóstico

El mercado eléctrico colombiano opera dentro de una estructura regulada por la Comisión de Regulación de Energía y Gas (CREG) y gestionada operativamente por XM. En este esquema participan generadores, transmisores, distribuidores, comercializadores y usuarios finales, quienes se agrupan en dos segmentos: el *Mercado Regulado*, donde las tarifas son definidas por la CREG, y el *Mercado No Regulado*, en el que usuarios industriales y comerciales pueden negociar directamente con los comercializadores.[6], [7] La energía se comercializa principalmente a través de la Bolsa de Energía, un mercado de operación continua administrado por XM, donde existe un precio de escasez que actúa como límite superior en las transacciones. La demanda eléctrica nacional ha mostrado un crecimiento sostenido, por ejemplo, en junio de 2024 aumentó un 4.53 % frente al mismo mes del año anterior.[8]

Dentro de esta estructura, el mercado mayorista exige que los generadores presenten ofertas con 24 horas de anticipación (*day-ahead*). [9], [10] Para las plantas solares fotovoltaicas, esto implica estimar con precisión la irradiancia y la generación horaria del día siguiente.

La CREG establece tolerancias de desvío: si la energía entregada difiere sustancialmente de lo ofertado, el generador enfrenta penalizaciones económicas. Por lo tanto, la calidad del pronóstico tiene un impacto financiero directo y determina la competitividad de los agentes en el mercado.

Adicionalmente, el país ha impulsado la generación distribuida mediante regulaciones como la Resolución CREG 174 de 2021 y la CREG 135 de 2021, que permiten a usuarios residenciales, comerciales e industriales inyectar excedentes a la red y recibir compensación económica. Este esquema reduce la dependencia del suministro convencional y protege a los usuarios frente a variaciones tarifarias. La expansión de la generación distribuida ha sido fortalecida por el *Programa Colombia Solar*, que financia hasta el 60 % de los sistemas fotovoltaicos para la economía popular, y por incentivos tributarios derivados de la Ley 1715 de 2014 (exenciones de IVA y aranceles, y deducciones en renta).[11]

En paralelo, grandes plantas solares participan en el mercado mayorista inyectando energía directamente al SIN. Su remuneración está sujeta al comportamiento del mercado, al precio de escasez y a su capacidad de cumplir las ofertas presentadas. La maduración del sector ha dado lugar a nuevos modelos de negocio como los contratos PPA (*Power Purchase Agreement*) y a la incorporación de sistemas de almacenamiento, que permiten gestionar la variabilidad inherente del recurso solar.

En conjunto, estos elementos revelan que un sistema eléctrico con creciente penetración de energía solar depende críticamente de pronósticos confiables de irradiancia y generación. Modelos precisos permiten reducir desviaciones penalizadas, optimizar la operación en la Bolsa de Energía, minimizar la volatilidad y fortalecer la integración de tecnologías limpias en la matriz energética colombiana.

Desafíos técnicos del pronóstico solar

A pesar de su abundancia, la energía solar presenta una marcada variabilidad asociada al clima y a la dinámica atmosférica. La irradiancia que llega a la superficie puede cambiar abruptamente debido al movimiento de nubes, a procesos convectivos y a interacciones locales entre orografía y cobertura nubosa; estos cambios se traducen directamente en variaciones de la generación en plantas fotovoltaicas y dificultan la planificación operativa.

Modelos físicos de predicción numérica del tiempo, como el *Global Forecast System* (GFS), ofrecen estimaciones atmosféricas globales, pero su resolución espacial y temporal, así como su desempeño en climas tropicales, limitan la precisión alcanzable a nivel de planta. En particular, en regiones como el Caribe colombiano, donde coexisten regímenes convectivos, advección de nubosidad y episodios de cielo parcialmente cubierto, los errores de pronóstico pueden ser significativos si solo se cuenta con salidas de modelos NWP de baja resolución.

Frente a estas limitaciones, han cobrado relevancia enfoques basados en datos (*data-driven*) que aprovechan mediciones locales de alta frecuencia y productos remotos como imágenes satelitales. Por un lado, los modelos tabulares construidos a partir de series históricas de GHI, variables meteorológicas y atributos astronómicos permiten capturar patrones temporales finos en un sitio concreto. Por otro lado, productos satelitales geoestacionarios (como GOES-16, a través de DSRF o MCMIPF) contienen información espacial sobre la distribución y evolución de nubes en un área amplia alrededor de la planta.

La integración efectiva de ambas fuentes plantea varios desafíos técnicos: sincronizar reso-

luciones temporales distintas (10 minutos en planta frente a 60 minutos en ciertos productos satelitales), manejar volúmenes de datos elevados, definir esquemas de recorte espacial representativos del entorno de la planta y diseñar arquitecturas de aprendizaje capaces de combinar información tabular estructurada con campos de imágenes. En este contexto, los modelos de inteligencia artificial, particularmente las redes neuronales recurrentes (LSTM, GRU, variantes dilatadas o modulares) y las arquitecturas híbridas que incorporan convoluciones sobre imágenes, se han consolidado como herramientas potentes para capturar dependencias temporales complejas y estructuras espaciales relevantes en series de irradiancia. Sin embargo, existe poca evidencia sistemática sobre su desempeño comparativo en entornos tropicales como el colombiano [12], especialmente cuando se contrasta explícitamente el camino puramente tabular frente a esquemas satelitales e híbridos.

Motivación y propósito del proyecto

En este marco, el presente trabajo se plantea dos motivaciones principales y complementarias. En primer lugar, comprender hasta qué punto un *dataset* tabular bien diseñado basado en mediciones locales de una planta fotovoltaica en El Paso (Cesar), enriquecidas con retardos, promedios móviles y variables astronómicas puede, por sí solo, ofrecer pronósticos de irradiancia competitivos frente a esquemas más complejos. En segundo lugar, evaluar el aporte real de la información satelital geoestacionaria al problema de pronóstico de corto plazo, comparando modelos construidos exclusivamente sobre imágenes con arquitecturas de fusión que combinan explícitamente información tabular y satelital.

Para ello, el proyecto desarrolla y contrasta dos grandes caminos de modelado:

- Un camino **puramente tabular**, que explota la estructura temporal de la serie de GHI y variables meteorológicas locales mediante modelos de referencia (regresión lineal, Random Forest) y arquitecturas recurrentes (LSTM, GRU, Dilated RNN, Clockwork RNN), todos evaluados de forma consistente en distintos horizontes de pronóstico.
- Un camino **satelital e híbrido**, que utiliza productos GOES-16 (principalmente DSRF, y de forma exploratoria MCMIPF) para construir modelos basados solo en imágenes (ConvLSTM) y modelos de fusión que integran un encoder satelital con un encoder tabular temporal.

De esta manera, se pretende aportar evidencia cuantitativa y operativamente relevante para agentes que participan en el mercado eléctrico colombiano: resultados que permitan dimensionar el valor agregado de incorporar información satelital en esquemas de pronóstico de planta, reducir la incertidumbre operativa asociada a penalizaciones por desvíos en ofertas *day-ahead* y, en última instancia, contribuir a un sistema energético más eficiente, resiliente y alineado con la transición hacia fuentes limpias.

Normatividad, regulaciones y estándares (nacional e internacional)

Cuadro 1: Normatividad y estándares aplicables a la energía solar en Colombia

Norma / Entidad	Descripción / Alcance
Ley 1715 de 2014	Marco legal principal para integrar las FNCER ¹ al sistema energético colombiano (incentivos tributarios, conexión, fomento de proyectos FV ²).
UPME (Unidad de Planeación Minero Energética)	Entidad de planeación energética: lineamientos, registro de proyectos FNCER y reglamentaciones técnicas.
CREG (Comisión de Regulación de Energía y Gas)	Regulación del sector eléctrico y de gas: conexión a red, tarifas, supervisión del mercado.
Ministerio de Minas y Energía	Política energética nacional: decretos, lineamientos de transición energética y autogeneración.
IEC 61724	Estándares internacionales de monitoreo y evaluación FV: medición de irradiancia y calidad de datos.
WMO / OMM	Estándares meteorológicos: calibración de piranómetros, formatos GRIB/BUFR usados por modelos NWP ³ .

Objetivos

Objetivo general

Desarrollar y comparar modelos tabulares, satelitales e híbridos para el pronóstico de irradiancia global horizontal (GHI) a corto plazo en una planta fotovoltaica del Caribe colombiano, evaluando su precisión, robustez y aplicabilidad operativa.

Objetivos específicos

- Construir un conjunto de datos unificado que integre mediciones locales, variables derivadas y productos satelitales GOES-16, mediante un pipeline reproducible de extracción y preprocesamiento.
- Evaluar el desempeño de modelos tabulares (basados en regresión, árboles de decisión y redes recurrentes) bajo múltiples horizontes de pronóstico.
- Desarrollar y analizar modelos satelitales y arquitecturas de fusión tabular+satelital para estudiar el aporte incremental de la información espacial.
- Comparar los modelos en función de métricas estándar (RMSE, MAE, R^2) y de indicadores operativos como *skill score* por hora del día y rango de irradiancia.
- Proponer criterios prácticos para seleccionar arquitecturas de pronóstico según horizonte, régimen de irradiancia y disponibilidad de datos.

Metodología

La metodología se organiza en cuatro componentes principales: (i) definición del caso de estudio y las fuentes de datos disponibles, (ii) construcción del *dataset* integrado a partir de mediciones en tierra e información satelital, (iii) diseño del esquema de modelado secuencial en formato tabular, y (iv) formulación de los modelos que integran explícitamente imágenes de GOES-16 con las variables de planta. En todos los casos se privilegia la reproducibilidad, la causalidad temporal y la comparabilidad entre arquitecturas.

Caso de estudio y fuentes de datos

El caso de estudio corresponde al pronóstico de *irradiancia global horizontal* (GHI) en una estación de medición ubicada en El Paso, Cesar, asociada a una planta fotovoltaica de referencia en el sistema colombiano. La base de datos original fue consolidada por Salazar-Peña et al.[12] en el marco de un proyecto de pronóstico intra-diario y se extiende en este trabajo mediante ingeniería de características, integración con productos satelitales y esquemas de modelado secuencial.

Datos sensados en tierra

Las mediciones terrestres provienen de una estación meteorológica y de planta FV con muestreo base de 10 minutos. Las variables consideradas en este trabajo incluyen:

- Irradiancia global horizontal (GHI) [W/m^2]
- Temperatura ambiente [$^{\circ}C$]
- Presión atmosférica [hPa]
- Velocidad y dirección del viento
- Hora

Estas señales constituyen la fuente primaria de información local. A partir de ellas se construyen variables derivadas (estadísticas móviles, retardos del objetivo, descriptores de variabilidad y relaciones no lineales) que alimentan los modelos tabulares y las ramas tabulares de los modelos híbridos.

Productos satelitales (GOES-16)

Para capturar el contexto espacial de nubosidad y radiación se integran productos del satélite geoestacionario GOES-16, parte del programa GOES de NOAA. Desde su órbita fija, GOES-16 monitorea de forma continua la atmósfera sobre el continente americano, proporcionando imágenes de alta frecuencia que permiten seguir la evolución de sistemas nubosos y sus impactos sobre la irradiancia en superficie. NASA construye y lanza los satélites, mientras NOAA los opera y distribuye sus datos.

El sensor principal, el *Advanced Baseline Imager* (ABI), adquiere imágenes en 16 bandas espectrales (visibles, infrarrojas cercanas e infrarrojas térmicas) con resoluciones de 0.5 a 2 km y una frecuencia de hasta 10 minutos.[13] La Figura 1 muestra un ejemplo de imagen de disco completo.




Figura 1: Ejemplo de imagen de disco completo de GOES-16 (producto MCMIPF) con área de interés sobre Colombia.

En este trabajo se utilizan dos familias de productos derivados de ABI:

- **DSRF (Downward Shortwave Radiation at the Surface).** Estimaciones de la radiación de onda corta descendente en superficie, construidas a partir de los canales visibles e infrarrojos de ABI, el albedo de superficie y la composición atmosférica.[14] Este producto aproxima directamente la GHI y proporciona mapas de irradiancia sobre el dominio continental. Para el presente estudio se recorta un parche fijo centrado en Colombia (Figura 2), que se utiliza tanto en modelos puramente satelitales como en arquitecturas de fusión.




Figura 2: Ejemplo de recorte de DSRF sobre el área de interés.

- **MCMIPF (Cloud and Moisture Imagery, Full Disk).** Composición multicanal de ABI con 16 bandas y resolución típica de 2 km cada 10 minutos, que caracteriza cobertura y tipo de nubes, vapor de agua y propiedades de superficie.[15] A partir de este producto se construyen secuencias multicanal en una región de 256×256 píxeles centrada en Colombia (Figura 3), que se transforman luego en entradas de menor tamaño para los modelos basados en CNN.




Figura 3: Recorte del producto MCMIPF sobre el área de interés.

Los productos DSRF y MCMIPF se procesan de forma sistemática para el periodo de estudio mediante una tubería desplegada en AWS (ingesta desde los buckets públicos de NOAA, recorte de área de interés y almacenamiento en formato comprimido). Los detalles operativos

de esta implementación se documentan en los anexos técnicos, aquí se considera únicamente el resultado de dicho flujo: secuencias de parches satelitales alineados temporalmente con las mediciones en planta.

Construcción del dataset integrado




Figura 4: Esquema general del flujo de construcción del *dataset* integrado.

El punto de partida es el archivo `Data.ElPaso.Clean.csv`, que contiene la serie de GHI y las principales variables meteorológicas medidas en sitio. Sobre esta base se construye un *dataset* tabular enriquecido y se sincroniza la información satelital correspondiente.

Regularización temporal y manejo de faltantes

Los registros de planta se ordenan cronológicamente y se eliminan marcas de tiempo duplicadas. Con base en la frecuencia predominante se define una malla temporal uniforme de 10 minutos y se reindexa la serie sobre dicha malla, de modo que todos los modelos trabajen con un paso de tiempo consistente.

Las filas completamente vacías se registran de forma explícita y se etiqueta la presencia de “objetivo faltante” para GHI, evitando que valores imputados se filtren inadvertidamente en el entrenamiento. Para el resto de variables se aplica imputación conservadora (mediana) tras el escalado, garantizando que las arquitecturas neuronales no reciban NaN ni infinitos.

Ingeniería de características tabulares

Sobre la serie regularizada se construyen capas adicionales de información derivada:

- **Variables temporales.** Hora local, día de la semana, mes e indicadores de fin de semana. Para capturar la periodicidad diaria y estacional se emplean codificaciones cíclicas seno/coseno de hora y día del año.
- **Descriptores astronómicos.** Empleando la librería `pvlib` se calcula la posición solar (cenit, azimuth, elevación), la irradiancia extraterrestre teórica y un índice de cielo despejado (*clear sky index*) a partir de GHI y del ángulo cenital. Estas variables permiten separar efectos puramente geométricos de la variabilidad asociada a nubosidad.

- **Estadísticas móviles y retardos.** Se generan promedios y máximos móviles de GHI, temperatura, presión y velocidad del viento en ventanas de 1, 3 y 6 horas, así como retardos (*lags*) del objetivo a distintos horizontes (10 – 360 minutos). Se incluyen también descriptores de variabilidad (cambios absolutos, desviación estándar en ventanas cortas) y medidas sencillas de persistencia.
- **Relaciones no lineales.** Se combinan variables mediante razones y productos (por ejemplo, razón temperatura/presión, interacciones viento–temperatura) para capturar efectos atmosféricos no lineales relevantes para la irradiancia.

Las características numéricas se estandarizan mediante **StandardScaler**, el objetivo GHI se escala de forma análoga durante el entrenamiento y se revierte al espacio original para reportar métricas.

Integración de parches satelitales

En paralelo, los productos DSRF y MCMIPF se procesan para construir secuencias espaciales alineadas con el índice temporal del *dataset* tabular. El flujo es, a alto nivel, el siguiente:

- Para cada hora del periodo de estudio se descargan los archivos correspondientes a DSRF y MCMIPF desde los buckets públicos de NOAA, se recorta un parche de 256×256 píxeles centrado sobre Colombia y se almacena en formato **.npz**.
- En el caso de MCMIPF, se conservan 16 bandas espectrales y se construye, para cada hora, una secuencia de seis *frames* de 10 minutos. Estas secuencias se utilizan más adelante para seleccionar el *frame* correspondiente a cada marca de tiempo de 10 minutos en el *dataset* de planta.
- Los parches DSRF y MCMIPF se remuestrean a tamaños más manejables (por ejemplo, 32×32 píxeles) y se normalizan canal a canal, usando medias y desviaciones estándar globales calculadas sobre todo el periodo.
- Finalmente, se construyen tensores satelitales S_t alineados con el índice temporal de las mediciones en tierra, de manera que para cada instante exista, cuando sea posible, un parche DSRF y un parche MCMIPF consistente.

El resultado de este proceso es un *dataset* integrado compuesto por: (i) una matriz tabular de características secuenciales y (ii) secuencias de imágenes satelitales alineadas en tiempo y espacio con la planta de referencia. Ambos insumos alimentan los esquemas de modelado descritos a continuación.

Modelado de series temporales en formato tabular

Formulación secuencial

El pronóstico de corto plazo se formula como un problema de regresión sobre series temporales con ventanas deslizantes. Dada una longitud de ventana T (en pasos de 10 minutos) y un horizonte de pronóstico H , cada muestra de entrenamiento se construye como:

$$\mathbf{X}_{t-T+1:t} \in \mathbb{R}^{T \times D} \quad \text{y} \quad y_{t+H} \in \mathbb{R},$$

donde D es el número de *features* tabulares por paso de tiempo y y_{t+H} corresponde a la GHI en el horizonte elegido (por ejemplo, 60 minutos en el futuro para $H = 6$). La generación de ventanas se realiza de forma estrictamente causal y respetando el orden temporal, con particiones 70 %/15 %/15 % para entrenamiento, validación y prueba.

Líneas base y modelos no secuenciales

Como referencia se consideran tres líneas base no secuenciales:

- **Persistencia**, definida por $\hat{y}_{t+H} = y_t$, que extrapola el último valor conocido de GHI.
- **Regresión lineal**, que modela y_{t+H} como combinación lineal de las características agregadas en una ventana.
- **Random Forest**, un ensamble de árboles de decisión entrenado sobre atributos agregados y retardos del objetivo.

El algoritmo *Random Forest* resulta particularmente atractivo como punto de comparación, al ser capaz de capturar relaciones no lineales entre variables sin requerir una arquitectura secuencial explícita.[16] La Figura 5 ilustra su estructura básica.




Figura 5: Esquema general de un modelo Random Forest.

Arquitecturas recurrentes

Sobre la misma formulación secuencial se entrenan cuatro arquitecturas recurrentes profundas:

LSTM. Las redes *Long Short-Term Memory* (LSTM) introducen celdas con compuertas de entrada, olvido y salida, lo que permite mantener y descartar información a distintas escalas temporales y mitigar el desvanecimiento del gradiente.[17] En este trabajo se utilizan LSTM unidireccionales con una a dos capas recurrentes y capas densas finales para mapear al escalar objetivo. La Figura 6 muestra la estructura interna de una celda LSTM.




Figura 6: Diagrama de una celda LSTM.[17]

GRU. Las *Gated Recurrent Units* (GRU) simplifican la estructura LSTM mediante compuertas de actualización y reseteo, reduciendo el número de parámetros y el costo computacional.[18] Se emplean GRU unidireccionales con una a tres capas recurrentes, enfocadas en capturar dependencias de mediano plazo en la irradiancia (Figura 7).




Figura 7: Diagrama de una celda GRU.[18]

RNN dilatada. Las RNN dilatadas introducen factores de dilatación d en la conexión recurrente, de modo que el estado oculto en t depende de $t - d$ en lugar de $t - 1$. [19] Esto amplía el campo receptivo temporal sin incrementar la profundidad efectiva de la red. En este trabajo se implementa una variante unidireccional donde la secuencia de entrada se submuestra con factores d seleccionados en el proceso de optimización (Figura 8).




Figura 8: Esquema de una RNN dilatada.[19]

Clockwork RNN. Las *Clockwork RNN* (CWRNN) dividen el estado oculto en módulos que se actualizan a frecuencias distintas (por ejemplo, cada 1, 2, 4, 8 pasos), lo que permite modelar simultáneamente dinámicas lentas (ciclo diario) y rápidas (paso de nubes).[20] Se utiliza una implementación con 3 – 5 módulos, con frecuencias definidas como potencias de dos sobre la longitud de la ventana de entrada (Figura 9).




Figura 9: Arquitectura general de una Clockwork RNN.[20]

Entrenamiento y regularización

Todas las redes neuronales se entrenan minimizando el error cuadrático medio (MSE) entre la GHI pronosticada y la observada, utilizando el optimizador Adam con tasas de aprendizaje en el rango 10^{-5} – 10^{-3} . Para mejorar la estabilidad se aplica *gradient clipping* (norma acotada), *EarlyStopping* con restauración del mejor modelo en validación y *ReduceLROnPlateau* para adaptar automáticamente la tasa de aprendizaje.

Las particiones entrenamiento/validación/prueba se definen de forma estrictamente temporal para evitar *look-ahead bias*. Todos los experimentos fijan semillas aleatorias y registran los parámetros relevantes, de modo que las corridas puedan reproducirse en el futuro.

Optimización de hiperparámetros con Optuna

La elección manual de hiperparámetros (tamaño oculto, número de capas, *dropout*, tasa de aprendizaje, longitud de ventana T , horizonte H , tamaño de lote, etc.) es costosa y propensa a sesgos. Para sistematizar este proceso se utiliza Optuna, un marco de optimización automática de hiperparámetros basado en búsqueda secuencial bayesiana (*Tree-structured Parzen Estimator*, *TPE*) y técnicas de *pruning* temprano.[21]

Para cada arquitectura se define un espacio de búsqueda *define-by-run* que incluye, entre otros:

- Tamaño oculto ($32 - 256$ unidades) y número de capas recurrentes ($1 - 3$).
- Tasas de *dropout* recurrente y en capas densas ($0,0 - 0,5$).
- Tasa de aprendizaje inicial (Adam) en el rango $10^{-5} - 10^{-2}$.
- Longitud de ventana T ($24-60$ pasos, equivalentes a $4 - 10$ horas).
- Horizontes de pronóstico H ($3, 6$ o 12 pasos, es decir $30-120$ minutos).
- Tamaño de lote ($32 - 256$) y penalización ℓ_2 sobre los pesos ($10^{-6} - 10^{-3}$).

Cada combinación propuesta por Optuna se entrena sobre el conjunto de entrenamiento y se evalúa en validación utilizando el RMSE como métrica objetivo. Un *MedianPruner* detiene de forma anticipada los ensayos cuyo desempeño intermedio es claramente inferior a la mediana de las corridas completadas, reduciendo el tiempo total de búsqueda. Una vez finalizados los ensayos, se selecciona la mejor configuración, se reentrena el modelo con datos de entrenamiento+validación y se reserva el conjunto de prueba exclusivamente para evaluación final (capítulo de Resultados).

Artefactos y reproducibilidad

Cada experimento guarda los artefactos esenciales: pesos entrenados, configuración de hiperparámetros, métricas de entrenamiento/validación y figuras de diagnóstico. Se fijan semillas aleatorias y se documenta el dispositivo de cómputo utilizado (CPU/GPU). De forma opcional, los estudios de Optuna se registran en un almacenamiento tipo *journal* y algunos entrenamientos se rastrean en MLflow, lo que facilita la comparación posterior entre modelos y la transferencia a entornos operativos.

Modelado integrando imágenes satelitales y datos tabulados

Además del esquema puramente tabular, se desarrollan modelos que integran explícitamente la información espacial de GOES-16 con las variables de planta. Se consideran tres familias de arquitecturas:

1. Modelos contruidos exclusivamente sobre imágenes satelitales (DSRF o MCMIPF).
2. Modelos puramente tabulares (descritos en la sección anterior).
3. Modelos híbridos que fusionan una rama satelital con una rama tabular secuencial.

En todos los casos se mantiene la resolución temporal de 10 minutos y las mismas particiones temporales de entrenamiento, validación y prueba.

ConvLSTM sobre DSRF (solo satélite)

El primer bloque satelital se basa en el producto DSRF, que proporciona estimaciones de radiación en superficie sobre una región amplia alrededor de la planta. Para evaluar su capacidad predictiva intrínseca se entrena un modelo *ConvLSTM* que utiliza exclusivamente parches DSRF como entrada.

- **Entrada.** Secuencias de longitud T compuestas por parches DSRF de tamaño reducido (por ejemplo, 32×32 píxeles con un canal), construidas a partir de recortes centrados en Colombia y normalizadas globalmente.
- **Arquitectura.** El modelo apila dos capas *ConvLSTM2D* con 16 y 32 filtros, seguidas de normalización por lotes, *dropout* espacial, *Global Average Pooling* y una capa densa intermedia de 64 unidades. Una neurona de salida predice la GHI a un horizonte fijo (típicamente 1 hora).
- **Esquema de entrenamiento.** Se utiliza Adam con aprendizaje en el orden de 10^{-4} , *gradient clipping* y los mismos mecanismos de parada temprana descritos para los modelos tabulares. Para controlar el costo computacional se genera el conjunto de ventanas con un *stride* mayor que uno.

Este modelo permite cuantificar qué fracción de la variabilidad de la irradiancia puede explicarse únicamente desde el patrón espacial de radiación estimada por GOES-16, sin recurrir a mediciones locales.

Fusión DSRF + tabular

Para explotar simultáneamente la información local de planta y el contexto espacial de GOES-16 se define un modelo híbrido que combina DSRF con el *dataset* tabular:

- **Rama satelital.** Secuencias de parches DSRF de longitud T se procesan mediante una CNN o un pequeño bloque ConvLSTM seguido de *Global Average Pooling*, generando un vector que resume la dinámica espacial de la irradiancia en el entorno de la planta.
- **Rama tabular.** La misma ventana de longitud T sobre las variables tabulares se procesa con una LSTM de 64 unidades (u otra arquitectura recurrente optimizada mediante Optuna), obteniendo un *embedding* que captura la memoria local de la serie.
- **Capa de fusión.** Ambos *embeddings* se concatenan y se pasan por una capa densa de 64 unidades con activación ReLU y *dropout*. Una neurona de salida estima la GHI en el horizonte H .

La idea central es que la rama tabular proporcione anclaje local y memoria detallada, mientras que la rama satelital aporta contexto espacial sobre el movimiento de nubes y la estructura de radiación a escala meso-local.

CNN-lite + LSTM sobre MCMIPF (solo satélite)

El segundo bloque satelital utiliza directamente el producto MCMIPF como entrada de un modelo de tipo *CNN+LSTM*. A diferencia de DSRF, MCMIPF conserva múltiples bandas espectrales que codifican tipos de nubes y estructura vertical de la atmósfera.

- **Construcción de las secuencias.** Para cada hora del periodo de estudio se dispone de seis *frames* de MCMIPF (10 minutos de separación) con 16 canales. Se selecciona un subconjunto de canales relevantes y se remuestrea cada *frame* a tamaños del orden de 32×32 píxeles. La normalización se realiza canal a canal sobre todo el periodo (media cero y desviación estándar unitaria).
- **Rama CNN-lite por *frame*.** Un bloque convolucional ligero procesa cada imagen de tamaño (H, W, C) , aplicando varias capas Conv–BN–Pooling y una capa de *Global Average Pooling* que comprime la información espacial en un *embedding* de dimensión fija.
- **Modelado temporal con LSTM.** Mediante una capa *TimeDistributed*, la CNN-lite se aplica a cada *frame* de la secuencia, generando una serie de *embeddings* que se pasan a una LSTM de 64 unidades. La salida de la LSTM se conecta a capas densas finales que producen la predicción de GHI en el horizonte deseado.

Esta arquitectura explota la estructura multicanal de MCMIPF y permite evaluar si las firmas espectrales de nubosidad aportan información adicional frente al producto DSRF.

Fusión MCMIPF + tabular

El mismo principio se extiende al producto MCMIPF mediante una arquitectura de fusión ligeramente más rica:

- **Rama MCMIPF.** Secuencias de longitud T de imágenes MCMIPF de tamaño reducido (H, W, C) se procesan con un bloque CNN-lite por *frame*, seguido de una LSTM temporal que resume la dinámica de la nubosidad multicanal alrededor de la planta.
- **Rama tabular.** Las secuencias tabulares se modelan con una LSTM de 64 unidades, como en el caso anterior.
- **Fusión y salida.** Los *embeddings* de ambas ramas se concatenan y pasan por una capa densa de fusión (64 unidades, ReLU, *dropout*), que finalmente se conecta a una neurona de salida para predecir la GHI en el horizonte H .

Este esquema permite comparar, bajo un mismo protocolo experimental, el aporte relativo de DSRF y MCMIPF cuando se integran con la información tabular de planta. Los resultados cuantitativos y la comparación detallada entre modelos tabulares, satelitales e híbridos se presentan en el capítulo de Resultados.

Resultados

En este capítulo se presentan los resultados del modelo puramente tabular y de los modelos satelitales e híbridos descritos en el capítulo de Metodología. Primero se analizan los modelos entrenados únicamente sobre el *dataset* tabular (variables meteorológicas, astronómicas y *features* derivadas). Luego se evalúa el aporte de la información satelital de GOES-16, tanto en modelos basados solo en imágenes como en arquitecturas de fusión con datos de planta.

Modelado tabular

El objetivo de esta sección es evaluar la capacidad predictiva de distintos modelos supervisados, con y sin memoria temporal, utilizando únicamente las variables derivadas del *dataset* histórico con resolución de 10 minutos. Se parte del conjunto de atributos descrito en el capítulo de Metodología (variables meteorológicas, índices astronómicos, representaciones cíclicas, retardos de GHI, promedios móviles y combinaciones no lineales).

Se estudiaron dos familias de modelos:

- **Modelos no secuenciales:** regresión lineal y Random Forest (versión baseline y versión optimizada vía Optuna).
- **Modelos secuenciales:** LSTM, GRU, Dilated RNN y Clockwork RNN, cada uno optimizado mediante búsqueda bayesiana con Optuna (120 ensayos por arquitectura en el modo de cómputo exigente).

En todos los casos se respetó una partición temporal estricta (70 % entrenamiento, 15 % validación, 15 % prueba). La métrica principal fue el RMSE, complementado con MAE, MAPE, sMAPE y R^2 , calculados siempre sobre el conjunto de prueba.

Métricas de desempeño global

La Tabla 2 resume el desempeño de cada modelo en el conjunto de prueba. Tres conclusiones principales se observan:

1. El **mejor modelo tabular** es el Random Forest optimizado, con un RMSE de $51,90 W/m^2$ y $R^2 \approx 0,974$.
2. Las cuatro variantes recurrentes (LSTM, GRU, Dilated y Clockwork) convergen a un desempeño muy similar, con $RMSE \approx 75 W/m^2$, sin superar a los modelos basados en árboles.

3. La persistencia constituye un baseline considerablemente débil ($\text{RMSE} \approx 146 \text{ W/m}^2$ y $R^2 \approx 0,80$), lo que confirma que los modelos efectivamente extraen información predictiva útil a partir de las variables derivadas.

Cuadro 2: Desempeño de modelos tabulares en el conjunto de prueba.

Modelo	RMSE (W/m^2)	MAE (W/m^2)	sMAPE (%)	R^2
Random Forest (Optuna)	51,90	19,17	53,97	0,974
Random Forest (baseline)	52,42	20,10	52,44	0,974
Regresión lineal	53,74	25,69	104,16	0,973
LSTM (Optuna)	75,34	36,00	106,69	0,946
GRU (Optuna)	75,20	38,63	106,89	0,946
Dilated RNN (Optuna)	75,01	40,89	109,82	0,947
Clockwork RNN (Optuna)	75,61	39,67	108,89	0,946
Persistencia	146,00	87,46	71,64	0,798

En términos de mejora respecto a la persistencia, se emplea el *skill score*

$$\text{Skill} = 1 - \frac{\text{RMSE}_{\text{modelo}}}{\text{RMSE}_{\text{persistencia}}},$$

de modo que valores positivos indican mejoras frente al baseline trivial. El Random Forest optimizado reduce el RMSE en aproximadamente un 64,5 %, mientras que las arquitecturas recurrentes logran mejoras del orden de 48 – 49 %.

Hiperparámetros óptimos

La Tabla 3 resume los hiperparámetros óptimos encontrados por Optuna para cada arquitectura. Para las RNNs, el mejor desempeño se obtuvo con ventanas de entrada entre 10 y 12 horas ($L = 60 - 72$ pasos de 10 minutos) y un horizonte base de 30 minutos (3 pasos), mientras que el Random Forest óptimo emplea un ensamble relativamente profundo con 500 árboles.

Cuadro 3: Hiperparámetros óptimos de los modelos tabulares (Optuna).

Modelo	L	Hor.	Unidades	Capas / Mód.	Dropout	Comentarios
LSTM	60	3	256	2 capas	0.023	$\text{lr}=1,5 \times 10^{-3}$, batch 128
GRU	72	3	256	3 capas	0.080	$\text{lr}=8,4 \times 10^{-4}$, batch 512
Dilated RNN	60	3	224	dil.=1	0.035	$\text{lr}=2,5 \times 10^{-3}$, batch 64
Clockwork RNN	60	3	210	5 mód., base 1	0.139	$\text{lr}=1,3 \times 10^{-3}$, batch 128
Random Forest	–	–	–	–	–	500 árboles, prof. 27, split 7, leaf 3

Estos resultados sugieren que las RNNs requieren memorias de varias horas para explotar la estructura temporal de la irradiancia, mientras que el Random Forest aprovecha la ingeniería de características sin necesidad de un modelado explícito de secuencias.

Comparación global entre modelos

La Figura 10 presenta la comparación directa de RMSE entre modelos. Destaca que:

- El Random Forest optimizado supera ligeramente a la versión baseline y a la regresión lineal, posicionándose como el mejor modelo tabular.
- Las cuatro RNNs exhiben un desempeño casi indistinguible entre sí, lo que indica que el límite observado está más relacionado con la información contenida en el *dataset* que con la arquitectura específica.
- Todos los modelos superan ampliamente a la persistencia, con mejoras superiores al 60 % en RMSE para los modelos basados en árboles.




Figura 10: Comparación de RMSE entre modelos tabulares en el conjunto de prueba.

Visualización temporal del desempeño

Las Figuras 11 muestran ejemplos de series temporales reales y predichas para el mejor modelo basado en árboles (Random Forest) y para cada arquitectura recurrente. Los patrones principales son:

- Todos los modelos reproducen correctamente la forma global del ciclo diario (amanecer, máximo al mediodía, atardecer).
- El Random Forest representa mejor la variabilidad intra-horaria y los picos asociados a nubes delgadas o bordes de nubosidad.
- Las RNNs tienden a suavizar picos y transiciones rápidas, lo cual contribuye a un RMSE ligeramente mayor y a una nube de dispersión más “aplanada”.




Figura 11: Ejemplos de predicción en el conjunto de prueba para Random Forest y arquitecturas recurrentes.

Dispersión predicho–real

Los gráficos de dispersión (Figura 12) permiten evaluar el sesgo estructural de las predicciones:

- El Random Forest muestra una nube de puntos más concentrada alrededor de la diagonal, particularmente en valores altos de GHI.
- La GRU (representativa de las RNNs) exhibe un aplanamiento de la nube en los máximos, consistente con la tendencia a suavizar la señal y a infraestimar picos de irradiancia.




Figura 12: Relación predicho–real para Random Forest (izq.) y GRU (der.) en el conjunto de prueba.

Error por condiciones solares

La Figura 13 muestra el RMSE segmentado según el rango de GHI real. Se observa que:

- El error mínimo se da en condiciones de muy baja irradiancia ($0 - 200 \text{ W/m}^2$), asociadas a noche o nubosidad muy espesa, donde la señal es prácticamente plana.
- El error crece con la intensidad de la irradiancia y alcanza su máximo en el rango $800 - 1200 \text{ W/m}^2$, dominado por alta variabilidad y cambios rápidos de nubosidad.
- El Random Forest mantiene menor RMSE que la GRU en todos los rangos, lo que refuerza la ventaja de los modelos de árboles sobre la familia recurrente bajo el esquema puramente tabular.





Figura 13: RMSE segmentado según el rango de GHI real para Random Forest y GRU.


Skill frente a persistencia por hora y horizonte

Las métricas globales entregan un único valor agregado sobre todo el periodo de prueba. Sin embargo, la complejidad física de la irradiancia no es homogénea en el tiempo: la estabilidad atmosférica, la organización de la nubosidad y la altura solar varían a lo largo del día, afectando directamente la predictibilidad.


Para capturar esta heterogeneidad se calculó, para cada arquitectura recurrente, el *skill score* relativo a la persistencia de forma condicional en dos dimensiones: **hora del día** y **horizonte de pronóstico**. Se consideraron horizontes de 10, 30 y 60 minutos (1, 3 y 6 pasos de 10 minutos), reentrenando cada arquitectura con los hiperparámetros óptimos encontrados por Optuna y ajustando únicamente el horizonte.




(a) LSTM – todos los horizontes.



(b) GRU – todos los horizontes.



(c) Dilated RNN – todos los horizontes.



(d) Clockwork RNN – todos los horizontes.

Figura 14: Skill relativo a la persistencia según hora del día y horizonte para las arquitecturas recurrentes (10, 30 y 60 minutos).

De los heatmaps de la Figura 14 se desprenden patrones coherentes entre arquitecturas:

- Skill fuertemente positivo en horas solares (07:00–17:00), donde se concentra la irradiancia significativa y la mayor variabilidad nubosa.
- Skill cercano a cero o negativo durante la noche (19:00–06:00), donde la irradiancia idealmente es nula y la persistencia reproduce casi perfectamente la trayectoria.
- Horizontes de 30 y 60 minutos mantienen skill positivo, indicando que los modelos aprenden dependencias de mediano plazo asociadas a la advección de nubosidad.
- Picos de skill entre 15:00 y 17:00, compatibles con escenarios de atmósfera relativamente más estable en la media tarde.
- Estructuras muy similares entre LSTM, GRU, Dilated y Clockwork, lo que sugiere que el límite de predictibilidad está impuesto por el fenómeno físico y por la información tabular disponible.

Para sintetizar esta información se calculó el skill medio en el intervalo 07:00–17:00 para cada horizonte y arquitectura (Figura 15). Se observa una tendencia clara: el skill medio aumenta con el horizonte y, para 60 minutos, todas las RNNs logran mejoras superiores al 35 % frente a la persistencia, con GRU y Clockwork ligeramente por encima de LSTM y Dilated.




Figura 15: Skill medio (07:00–17:00) por horizonte de pronóstico para las cuatro arquitecturas recurrentes.

Resumen

La Tabla 4 resume de forma compacta el desempeño de los modelos tabulares, destacando la mejora relativa respecto a la persistencia y el rol cualitativo de cada arquitectura.

Cuadro 4: Resumen sintético de desempeño de los modelos tabulares.

Modelo	RMSE (W/m^2)	Mejora vs. persistencia (%)	R^2	Comentario principal
Random Forest (Optuna)	51,90	64,5	0,974	Mejor modelo tabular, captura bien la variabilidad intra-horaria y reduce significativamente los errores frente a persistencia.
Random Forest (baseline)	52,42	64,1	0,974	Versión sin búsqueda bayesiana, desempeño muy cercano al óptimo, lo que indica robustez de la familia de árboles.
Regresión lineal	53,74	63,2	0,973	Modelo simple que ya capta buena parte de la estructura, sirve como referencia lineal fuerte.
LSTM (Optuna)	75,34	48,4	0,946	RNN con skill positivo en horas solares, tiende a suavizar picos y transiciones rápidas.
GRU (Optuna)	75,20	48,5	0,946	Performance muy similar a LSTM, ligeramente mejor skill medio en horizontes largos.
Dilated RNN (Optuna)	75,01	48,6	0,947	Arquitectura con muestreo dilatado, patrón de skill casi idéntico a LSTM/GRU.
Clockwork RNN (Optuna)	75,61	48,2	0,946	Modelo modular por escalas temporales, buen skill para 30–60 min pero sin superar a los árboles en RMSE global.
Persistencia	146,00	0,0	0,798	Baseline trivial, adecuado solo como referencia, con errores muy superiores en horas solares.

En conjunto, bajo un esquema puramente tabular, la combinación de **ingeniería de características** y **modelos de árboles** ofrece el mejor compromiso entre precisión y complejidad. Las arquitecturas recurrentes proporcionan un análisis más rico en términos de skill horario y de horizonte, pero su desempeño global se ve limitado por la falta de información espacial, lo que motiva la integración posterior de datos satelitales en modelos de fusión.

Modelado híbrido tabular + satelital

En esta sección se evalúa el aporte de la información satelital de GOES-16 al pronóstico de GHI, utilizando el producto de radiación en superficie DSRF como fuente principal de

señal espacial.

Se consideran dos arquitecturas, ya descritas en detalle en el capítulo de Metodología:

1. Un modelo ConvLSTM alimentado únicamente con secuencias de parches DSRF (modelo “solo satélite”).
2. Un modelo de fusión que integra un encoder satelital (DSRF) con un encoder tabular temporal, ambos entrenados de forma conjunta.

En todos los casos se mantiene la resolución temporal de 10 minutos y se respetan las mismas particiones temporales de entrenamiento, validación y prueba utilizadas en el modelado puramente tabular.

Modelo ConvLSTM con DSRF (solo satélite)

El primer experimento satelital cuantifica la capacidad predictiva de las imágenes DSRF por sí solas, sin apoyo de las mediciones locales de planta. Se emplea el modelo ConvLSTM ligero descrito en Metodología, alimentado con secuencias de 24 parches DSRF de tamaño 32×32 píxeles (aproximadamente 4 horas de historia a resolución de 10 minutos), normalizadas globalmente.

En el conjunto de prueba, el modelo ConvLSTM DSRF obtuvo:

$$\text{RMSE} \approx 106,39 \text{ W/m}^2, \quad \text{MAE} \approx 58,79 \text{ W/m}^2, \quad R^2 \approx 0,892,$$

con un sMAPE medio cercano al 112 %. El valor de R^2 indica que el satélite, incluso sin información local, captura una fracción relevante de la variabilidad de la irradiancia. Sin embargo, el error absoluto sigue siendo notablemente superior al de los modelos tabulares basados en mediciones de planta (por ejemplo, el Random Forest optimizado con $\text{RMSE} \approx 52 \text{ W/m}^2$).

Las Figuras 16 y 17 ilustran el desempeño temporal del modelo ConvLSTM sobre el conjunto de prueba, tanto en una muestra larga como en dos días consecutivos.




Figura 16: Desempeño del modelo ConvLSTM DSRF en el conjunto de prueba (muestra larga).




Figura 17: Desempeño del ConvLSTM DSRF durante dos días consecutivos del conjunto de prueba.

En síntesis, el DSRF por sí solo contiene señal útil sobre la dinámica de nubes y sombras a escala horaria, pero no es suficiente para competir con un modelo bien alimentado por variables locales y *features* derivadas.

Modelo de fusión DSRF + tabular

El segundo experimento introduce una arquitectura híbrida que combina explícitamente la información satelital DSRF con el *dataset* tabular construido a partir de las mediciones en El Paso. La hipótesis es que el satélite aporta contexto espacial (movimiento y estructura de nubes) que complementa la visión local de la estación.

El modelo consta de dos ramas: (i) una rama satelital que procesa secuencias de 24 parches DSRF mediante una CNN ligera y una LSTM temporal, y (ii) una rama tabular que modela, con otra LSTM, la misma ventana de longitud T sobre las variables meteorológicas y astronómicas. Las salidas de ambas ramas se concatenan y se proyectan a una única predicción de GHI a 1 hora.

En el conjunto de prueba, el modelo de fusión DSRF + tabular alcanzó:

$$\text{RMSE} \approx 86,39 \text{ W/m}^2, \quad \text{MAE} \approx 43,80 \text{ W/m}^2, \quad R^2 \approx 0,929,$$

con sMAPE medio alrededor de 109 %. Estos resultados son claramente mejores que los del modelo ConvLSTM puro y superiores a los de la persistencia, pero todavía se sitúan por debajo de los mejores modelos tabulares (Random Forest y RNNs optimizadas, con RMSE en el rango 52–75 W/m²).

Las Figuras 18 y 19 muestran la respuesta temporal del modelo de fusión sobre el conjunto de prueba.




Figura 18: Desempeño del modelo de fusión DSRF + tabular en el conjunto de prueba (muestra larga).




Figura 19: Desempeño del modelo de fusión durante dos días consecutivos del conjunto de prueba.

Comparación cuantitativa

La Tabla 5 resume los resultados de los modelos satelitales e híbridos, junto con el mejor modelo puramente tabular, para facilitar la comparación directa.

Cuadro 5: Desempeño comparado de modelos satelitales e híbridos.

Modelo	RMSE (W/m^2)	MAE (W/m^2)	sMAPE (%)	R^2
Random Forest (tabular, Optuna)	51,90	19,17	53,97	0,974
ConvLSTM DSRF (solo satélite)	106,39	58,79	111,80	0,892
Fusión DSRF + tabular	86,39	43,80	109,31	0,929

Tres conclusiones cuantitativas claras se desprenden de la Tabla 5:

1. El modelo ConvLSTM basado únicamente en DSRF **no es competitivo** frente a los modelos tabulares: su RMSE es aproximadamente el doble que el del Random Forest optimizado y su sMAPE refleja una dispersión elevada.

2. La fusión DSRF + tabular reduce el RMSE frente al ConvLSTM puro (de ~ 106 a ~ 86 W/m^2) y eleva el R^2 de $\sim 0,89$ a $\sim 0,93$, lo que muestra que la información satelital y la tabular son *complementarias*.
3. A pesar de esta mejora, el modelo híbrido no logra aún alcanzar al Random Forest tabular ni a las mejores RNN tabulares, que mantienen el mejor compromiso entre error y complejidad arquitectónica bajo las configuraciones probadas.

La Figura 20 descompone el error absoluto medio por rangos de irradiancia para los modelos ConvLSTM DSRF y fusión DSRF+tabular.




Figura 20: Error absoluto medio (MAE) segmentado por rangos de irradiancia para los modelos ConvLSTM DSRF y fusión DSRF+tabular.

Se observa que el error depende fuertemente del régimen de irradiancia: es bajo en cielos muy despejados o muy nublados y alcanza su máximo en rangos intermedios ($200 - 600$ W/m^2), típicos de nubosidad variable. El modelo de fusión DSRF+tabular reduce el error en todos los rangos y ofrece su mayor beneficio precisamente en estos regímenes intermedios, donde la información satelital aporta contexto espacial que los modelos solo tabulares no captan. En irradiancias muy altas, el error aumenta de nuevo principalmente por desfases temporales, donde un adelanto o retraso de 10 minutos puede producir diferencias grandes cerca del pico diario.

Resumen

Desde el punto de vista puramente numérico, los experimentos satelitales e híbridos muestran que:

- La información satelital de GOES-16, utilizada de forma aislada (ConvLSTM sobre DSRF), captura una fracción sustancial de la variabilidad de la irradiancia pero no alcanza la precisión de los modelos entrenados sobre mediciones locales.

- La fusión explícita de DSRF con el *dataset* tabular mejora de forma consistente el desempeño frente al modelo solo satélite, confirmando que las dos fuentes de información son complementarias.
- Incluso con esta fusión, los mejores resultados globales se obtienen todavía con el esquema puramente tabular basado en Random Forest y *features* diseñadas, que define la línea base a superar por modelos híbridos más sofisticados (por ejemplo, incorporando MCMIPF multicanal).

Los aspectos físicos, operativos y de costo computacional asociados a estos resultados se discuten en detalle en el capítulo de Discusión.

Discusión

Desempeño de los modelos tabulares

Los resultados del capítulo anterior muestran que, con un *dataset* tabular bien diseñado, es posible lograr niveles de error relativamente bajos en el pronóstico de GHI a corto plazo. El Random Forest optimizado alcanza un RMSE cercano a 52 W/m^2 y un R^2 próximo a 0.97, lo que implica que la variabilidad de la irradiancia a escala de 10 minutos está fuertemente condicionada por las variables meteorológicas locales, los descriptores astronómicos y la memoria reciente codificada en retardos y estadísticas móviles.

El hecho de que la regresión lineal se acerque mucho al desempeño de Random Forest sugiere que una proporción importante de la estructura de la serie es aproximadamente lineal cuando se trabaja con *features* adecuadas. No obstante, el margen adicional que ofrecen los árboles indica que existen no linealidades relevantes (por ejemplo, en las relaciones temperatura presión o viento índice de cielo despejado) que las técnicas lineales no capturan del todo.

Las arquitecturas recurrentes (LSTM, GRU, Dilated y Clockwork) proporcionan un *skill* claramente positivo frente a la persistencia, pero no logran superar a los modelos de árboles. Esta brecha se explica, en parte, por el hecho de que gran parte de la memoria relevante ya está codificada explícitamente en las *features* tabulares, la capacidad adicional de las RNNs para modelar dependencias de largo plazo agrega información marginal limitada bajo el esquema actual de atributos.

Skill horario y horizontes de pronóstico

El análisis del *skill score* por hora del día y horizonte confirma que la dificultad del problema no es homogénea en el tiempo. En horas solares (07:00 17:00), los modelos recurrentes mejoran consistentemente la persistencia, con especial énfasis en horizontes de 30 60 minutos. Esto sugiere que la dinámica de la irradiancia en esos rangos está dominada por procesos de advección de nubosidad que tienen cierta coherencia temporal y son, por tanto, parcialmente predecibles.

En contraste, durante la noche el *skill* tiende a cero o incluso a valores negativos: la serie de GHI se aproxima a cero de forma casi constante, de modo que la persistencia ofrece un baseline muy difícil de superar. Desde una perspectiva operativa, este comportamiento no representa una limitación relevante, pues la generación fotovoltaica es nula en esos periodos y el interés práctico se concentra en horas solares.

La estabilidad del *skill* en horizontes de hasta 60 minutos es particularmente importante

para mercados intradiarios y esquemas de despacho de corta anticipación. Indica que, con la información disponible, es razonable esperar mejoras sostenidas frente a la persistencia en horizontes compatibles con la operación real de una planta FV.

Aporte de la información satelital

Los experimentos con DSRF muestran que la información satelital, utilizada de manera aislada, captura una fracción significativa de la variabilidad de la irradiancia ($R^2 \approx 0,89$), pero con errores aún demasiado altos para desplazar a los modelos basados en datos de planta. Esta diferencia se puede atribuir a varios factores:

- La resolución espacial de los parches (del orden de 32×32 píxeles) y la naturaleza promediada de DSRF, que puede suavizar efectos microclimáticos relevantes a escala de planta.
- La ausencia de información local sobre condiciones específicas del sitio (albedo, suciedad de paneles, sombreados parciales, etc.), que sí está implícita en las mediciones de la estación.
- La sensibilidad del modelo ConvLSTM a pequeños errores de georreferenciación o desalineamientos temporales entre el campo satelital y la serie de GHI.

Cuando se combina DSRF con el *dataset* tabular, el modelo híbrido reduce el RMSE y aumenta el R^2 frente al modelo solo satélite, lo que confirma que ambas fuentes de información son complementarias. La mejora es especialmente visible en rangos intermedios de irradiancia ($200 - 600 \text{ W/m}^2$), donde la nubosidad parcial genera cambios bruscos en GHI. En este régimen, el contexto espacial de GOES-16 ofrece una ventaja que los modelos puramente tabulares no pueden explotar.

Sin embargo, incluso con esta fusión, los modelos tabulares siguen marcando la referencia en términos de error global. Esto sugiere que, en la configuración actual, el cuello de botella está más en la explotación de la información satelital (tipo de producto, resolución, arquitectura de visión) que en la capacidad de los modelos para absorber nuevas *features*.

Implicaciones operativas

Desde un punto de vista práctico, los resultados permiten plantear varios escenarios de uso:

- Para un operador que dispone de mediciones confiables de planta, un modelo tabular bien diseñado (por ejemplo, Random Forest con *features* astronómicas y meteorológicas) ofrece actualmente el mejor compromiso entre precisión, estabilidad y coste computacional.
- Los modelos híbridos con DSRF resultan atractivos como capa de respaldo frente a fallos parciales de la estación (sensores fuera de servicio, lagunas en la serie de GHI), ya que aportan información espacial que no depende de la instrumentación local.

-
- La explotación de mapas de error por rango de irradiancia y de *skill* horario permite definir ventanas de confianza para el uso de los modelos, ajustando las estrategias de despacho y cobertura de riesgo en función de la hora del día y las condiciones radiativas esperadas.

Costos computacionales y complejidad de modelos

La comparación entre Random Forest, RNNs tabulares y modelos híbridos pone en evidencia una relación clara entre costo computacional y ganancia marginal:

- Los modelos de árboles entrenados sobre *features* tabulares son relativamente baratos de entrenar y de desplegar, con tiempos de inferencia muy bajos y sin necesidad de GPU.
- Las RNNs tabulares requieren más tiempo de entrenamiento y recursos de cómputo (especialmente cuando se combinan con Optuna), pero no ofrecen una mejora sustancial en RMSE frente a Random Forest bajo el *dataset* actual.
- Los modelos ConvLSTM e híbridos con imágenes DSRF implican un salto en complejidad: necesitan GPU, manejan tensores de mayor dimensión y son más sensibles a detalles de normalización y alineación. La mejora obtenida al combinar DSRF con datos tabulares es clara frente al modelo solo satélite, pero todavía insuficiente para justificar, por sí sola, el reemplazo de los modelos puramente tabulares.

En otras palabras, el uso de información satelital tiene sentido cuando se busca robustez adicional o cuando no se dispone de mediciones locales de buena calidad, pero no desplaza automáticamente a los modelos tabulares como primera opción operativa.

Limitaciones y alcances del estudio

Los resultados presentados en este trabajo deben interpretarse dentro de un conjunto de condiciones muy específicas de dominio, datos y diseño de modelos. En particular, el hecho de que los modelos puramente tabulares superen a las arquitecturas basadas en imágenes satelitales *no implica* que la información de GOES-16 sea intrínsecamente inferior o prescindible, sino que, bajo el contexto considerado, los modelos de árboles y RNNs tabulares logran explotar mejor la señal disponible.

En primer lugar, el **dominio geográfico** está restringido a una sola planta fotovoltaica ubicada en El Paso (Cesar), con condiciones climáticas y patrones de nubosidad muy particulares. Es posible que en otros contextos geográficos por ejemplo, regiones con nubosidad más organizada a gran escala, mayor influencia frontal o menos efecto microclimático local la información satelital tenga un peso relativo mayor y pueda incluso superar a los modelos entrenados exclusivamente con datos de planta. Por tanto, las conclusiones sobre la comparación entre enfoques tabulares e híbridos no son directamente generalizables a todo el territorio colombiano ni a otras zonas tropicales sin estudios adicionales.

En segundo lugar, la **longitud y calidad de la serie histórica** constituyen otra limitación relevante. El periodo de datos utilizado, aunque suficiente para entrenar y validar

modelos robustos en el sitio de estudio, sigue siendo relativamente acotado si se piensa en escalas climáticas o en la caracterización exhaustiva de patrones raros (eventos extremos, temporadas atípicas, etc.). Es razonable esperar que, con una serie histórica más extensa y diversa, tanto los modelos tabulares como los híbridos en particular los basados en imágenes puedan mejorar su capacidad de generalización y aprovechar mejor la información temporal de largo plazo.

En cuanto a la **información satelital**, este trabajo se concentra en el producto DSRF con parches 32×32 y una única banda efectiva de radiación en superficie. No se exploran estrategias de preprocesamiento más avanzadas (por ejemplo, extracción de *features* físicos derivados, composición de nubes, índices de desarrollo convectivo, etc.). Tampoco se consideran arquitecturas de visión más sofisticadas (U-Net, CNN 3D, *transformers* espaciales) que podrían explotar mejor la estructura espacial y temporal de las imágenes. En este sentido, las conclusiones sobre el desempeño limitado de los modelos satelitales e híbridos están condicionadas por una combinación concreta de producto, resolución y arquitectura.

Una cuarta limitación está en la forma de fusión entre información estructurada y no estructurada. La arquitectura híbrida implementada realiza una fusión relativamente sencilla: embeddings extraídos de las imágenes DSRF y de la serie tabular se concatenan y se proyectan a una salida escalar. Existen esquemas alternativos de fusión (por ejemplo, atención cruzada entre ramas, *gating* dinámico según condiciones de irradiancia, jerarquías espaciales temporales más profundas) que podrían redistribuir mejor el peso relativo de cada fuente de información y, en consecuencia, mejorar los resultados. Que la fusión aquí probada no supere a los modelos tabulares no descarta que otros diseños híbridos más avanzados sí lo logren.

También existe una dimensión de **restricciones computacionales y de exploración de hiperparámetros**. Tanto los modelos ConvLSTM como las arquitecturas híbridas con imágenes son costosos en términos de GPU, memoria y tiempo de entrenamiento. Esto obligó a limitar el espacio de búsqueda de Optuna, el tamaño de los modelos y la resolución de las ventanas temporales, así como a trabajar con parches relativamente pequeños y *strides* discretos en la generación de secuencias. Es posible que, con recursos computacionales más amplios, resulten competitivas arquitecturas más profundas o esquemas de entrenamiento más agresivos (por ejemplo, preentrenamiento en periodos largos y *fine-tuning* local).

Finalmente, el estudio se centra en un conjunto concreto de **métricas de error** (RMSE, MAE, sMAPE, R^2) y en horizontes de 10 60 minutos. No se analiza de forma explícita el impacto de los errores en términos económicos (costos de desvío en mercado, penalizaciones, valorización de rampas), ni se consideran horizontes más largos que podrían ser más sensibles al aporte satelital. En otros contextos de aplicación por ejemplo, planificación intradiaria a varias horas vista o gestión de portafolios multi-planta la evaluación relativa de los modelos podría cambiar.

En conjunto, estas limitaciones acotan el alcance de las conclusiones: los resultados muestran que, *para el sitio, periodo, productos satelitales y arquitecturas específicos de este trabajo*, los modelos tabulares bien diseñados siguen siendo la referencia en términos de precisión global, mientras que los modelos híbridos con imágenes DSRF aportan mejoras parciales en ciertos regímenes de irradiancia pero no los superan. No obstante, la propia estructura del problema sugiere que, al diversificar el dominio geográfico, ampliar la serie histórica y explorar formas alternativas de combinar información estructurada y no estructurada, el rol relativo de las imágenes satelitales podría ser mucho más favorable que el observado aquí.

Conclusiones

Conclusiones principales

1. Bajo el esquema propuesto, la combinación de **ingeniería de características** y **modelos de árboles** permite alcanzar errores de pronóstico de GHI del orden de $52 W/m^2$ a 10 minutos de resolución, con $R^2 \approx 0,97$. Esto demuestra que buena parte de la variabilidad de corto plazo puede capturarse a partir de variables meteorológicas locales, descriptores astronómicos y memoria reciente de la serie.
2. Las arquitecturas recurrentes entrenadas sobre el mismo *dataset* tabular logran mejoras significativas frente a la persistencia, especialmente en horizontes de 30 – 60 minutos y en horas solares, pero no superan el desempeño de Random Forest. El valor añadido de las RNNs parece limitado por la riqueza del propio *dataset* y no tanto por la capacidad de las arquitecturas.
3. La información satelital de GOES-16 (producto DSRF) contiene señal predictiva relevante y, empleada de forma aislada con un modelo ConvLSTM, alcanza R^2 cercanos a 0.89. No obstante, su error absoluto sigue siendo demasiado alto para desplazar a los modelos basados en mediciones de planta.
4. La fusión explícita de DSRF con el *dataset* tabular mejora de forma consistente el desempeño frente al modelo solo satélite y reduce el error en rangos de irradiancia intermedios, donde la nubosidad parcial genera la mayor incertidumbre. Esto confirma que la información satelital y la tabular son complementarias y que los modelos híbridos son una línea de trabajo prometedora.
5. A pesar de estas mejoras, el modelo híbrido evaluado no logra todavía alcanzar al Random Forest tabular. La evidencia sugiere que es necesario explorar productos satelitales más ricos y arquitecturas de visión más avanzadas para que la integración de imágenes tenga un impacto decisivo en el error global.

Referencias

- [1] N. K. M. A. Alrikabi, «Renewable Energy Types,» *Journal of Clean Energy Technologies*, págs. 61-64, 2014. DOI: 10.7763/jocet.2014.v2.92
- [2] XM, Operador del Sistema Interconectado Nacional. «En el cuarto trimestre, 37 proyectos de transmisión y 67 de generación ingresaron para fortalecer el Sistema Interconectado Nacional.» Comunicado oficial. dirección: <https://www.xm.com.co/noticias/7491-en-el-cuarto-trimestre-37-proyectos-de-transmision-y-67-de-generacion-ingresaron-para>
- [3] Energía Estratégica. «Colombia supera los 2.2 GW solares: ¿Cuáles son las empresas con más capacidad operativa?» Dirección: <https://www.energiaestrategica.com/colombia-supera-los-22-gw-solares-cuales-son-las-empresas-con-mas-capacidad-operativa/#:~:text=Colombia%20super%C3%B3%20los%202%2C2,1a%20cadena%20de%20valor%20fotovoltaica>.
- [4] Ministerio de Minas y Energía de Colombia. «Plan 6GW Plus: del 2 % al 13.87 %, Colombia da un salto histórico hacia las energías limpias.» Boletín de prensa. dirección: <https://www.minenergia.gov.co/es/sala-de-prensa/noticias-index/plan-6gw-plus-del-2-al-1387-colombia-da-salto-historico-hacia-energias-limpias/#:~:text=El%20Plan%20tiene%20la%20meta,energ%C3%ADa%20limpia%20en%20su%20matriz>.
- [5] XM, Operador del Sistema Interconectado Nacional. «Informe de Operación del Sistema y Administración del Mercado 2024.» Reporte integral de sostenibilidad, operación y mercado. dirección: <https://www.xm.com.co/reporte-integral-de-sostenibilidad-operacion-y-mercado-2024>
- [6] E. Energy. «Mercado Regulado y No Regulado de Energía en Colombia.» Consulta: marzo 2025. dirección: <https://erco.energy/co/blog/mercado-regulado-no-regulado-energia-colombia>
- [7] E. X. «¿Cómo funciona la energía en Colombia? Conoce su cadena de valor.» Consulta: marzo 2025. dirección: <https://www.enelxenergy.com/Home/blog/energia-para-empresas/energia-en-colombia.html>
- [8] X. S. E.S.P. «En junio, la demanda de energía en Colombia aumentó 4.53 % en comparación con el mismo mes del año anterior.» Consulta: marzo 2025. dirección: <https://www.xm.com.co/noticias/8044-en-junio-la-demanda-de-energia-en-colombia-aumento-453-en-comparacion-con-el-mismo>

- [9] Comisión de Regulación de Energía y Gas (CREG). «Resolución 024 de 1995. Por la cual se reglamentan los aspectos comerciales del mercado mayorista de energía en el Sistema Interconectado nacional, que hacen parte del Reglamento de Operación.» Diario Oficial No. 41.937 del 24 de julio de 1995, visitado 1 de mar. de 2025. dirección: https://gestornormativo.creg.gov.co/gestor/entorno/docs/resolucion_creg_0024_1995.htm
- [10] Comisión de Regulación de Energía y Gas (CREG). «Resolución 060 de 2019. Por la cual se hacen modificaciones y adiciones transitorias al Reglamento de Operación para permitir la conexión y operación de plantas solares fotovoltaicas y eólicas en el SIN y se dictan otras disposiciones.» Diario Oficial No. 51.004 del 4 de julio de 2019, visitado 1 de mar. de 2025. dirección: https://gestornormativo.creg.gov.co/gestor/entorno/docs/resolucion_creg_0060_2019.htm
- [11] M. de Minas y Energía de Colombia. «Decreto 2025-02-28: Programa Colombia Solar y reglamentación para autogeneración en estratos 1, 2 y 3.» Consulta: marzo 2025. dirección: https://www.minenergia.gov.co/documents/13280/2025-02-28_Decreto_Colombia_Solar.pdf
- [12] N. Salazar-Pena et al., «Intra-day Solar and Power Forecast for Optimization of Intra-day Market Participation,» *arXiv preprint*, 2025. DOI: 10.48550/arXiv.2501.09551 arXiv: 2501.09551 [cs.LG]. dirección: <https://arxiv.org/abs/2501.09551>
- [13] NOAA GOES-R Program, *Advanced Baseline Imager (ABI)*, <https://www.goes-r.gov/spacesegment/abi.html>, Accessed: [November, 2025], 2025.
- [14] NOAA National Centers for Environmental Information (NCEI), *GOES-R Downward Shortwave Radiation: Surface (DSR)*, 2018. DOI: 10.7289/V59P2Z7T dirección: <https://www.ncei.noaa.gov/access/metadata/landing-page/bin/iso?id=gov.noaa.ncdc:C01524>
- [15] NOAA National Centers for Environmental Information (NCEI), *GOES-R Cloud and Moisture Imagery Products (CMIP)*, 2018. DOI: 10.7289/V5D21V3Q dirección: <https://www.ncei.noaa.gov/access/metadata/landing-page/bin/iso?id=gov.noaa.ncdc:C01502>
- [16] A. Jain. «Everything about Random Forest.» Medium article, visitado 1 de mar. de 2025. dirección: <https://medium.com/@abhishekjainindore24/everything-about-random-forest-90c106d63989>
- [17] J. Luo, Z. Zhang, Y. Fu y F. Rao, «Time series prediction of COVID-19 transmission in America using LSTM and XGBoost algorithms,» *Results in Physics*, vol. 27, pág. 104462, jun. de 2021. DOI: 10.1016/j.rinp.2021.104462
- [18] S. Mohsen, «Recognition of human activity using GRU deep learning algorithm,» *Multimedia Tools and Applications*, vol. 82, mayo de 2023. DOI: 10.1007/s11042-023-15571-y
- [19] M. Titos, J. Carthy, L. García, T. Barnie y C. Benitez, «Dilated-RNNs: A Deep Approach for Continuous Volcano-Seismic Events Recognition,» *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. PP, págs. 1-9, ene. de 2024. DOI: 10.1109/JSTARS.2024.3421921

- [20] J. Koutník, M. Gascuel, B. Schrauwen y J. Schmidhuber, «A Clockwork RNN,» en *Proceedings of the 31st International Conference on Machine Learning*, ép. JMLR Workshop and Conference Proceedings, vol. 32, JMLR Workshop y Conference Proceedings, 2014, págs. 1863-1871. dirección: <http://proceedings.mlr.press/v32/koutnik14.pdf>
- [21] T. Akiba, S. Sano, T. Yanase, T. Ohta y M. Koyama, *Optuna: A Hyperparameter Optimization Framework*, <https://optuna.org/>, Accessed: 2025-02-20, 2019.

Anexos

Enlace a repositorio

`https://github.com/EstebanLN/solar-forecasting-colombia`

Instructivo para la Descarga de Productos GOES usando AWS

Instructivo para la Ingesta de Datos GOES (ABI-L2-MCMIPF y ABI-L2-DSRF) con AWS CLI y AWS Lambda (Imagen Docker)

Esteban Ladino Nieto
Proyecto de Grado, Universidad de los Andes

17 de noviembre de 2025

Resumen

Este documento describe un flujo reproducible para descargar, procesar y almacenar los productos satelitales **GOES ABI-L2-MCMIPF** y **ABI-L2-DSRF** usando exclusivamente:

- **AWS CLI**
- **AWS Lambda** ejecutada desde una **imagen Docker**
- **Amazon S3** para almacenamiento final

El procesamiento incluye recorte espacial sobre **Colombia**, reducción a 256×256 píxeles y empaquetado eficiente en **.npz**. La ingesta a gran escala se realiza mediante un script **backfill** idempotente, el cual reenvía únicamente horas faltantes detectadas dinámicamente en S3.

Nota — GOES-East (2025). Desde abril de 2025, GOES-19 reemplazó a GOES-16 como satélite operativo del Este. El flujo funciona igual apuntando a **noaa-goes16** (histórico) o **noaa-goes19** (reciente).

Arquitectura Final Implementada

- **Amazon S3 (bucket del proyecto)**
 - Bucket: **goes-data-esteban-2025**
 - Estructura organizada:


```
processed/
  MCMIPF/YYYY/MM/  -> YYYYMMDD_HH_MCMIPF.npz
  DSRF/YYYY/MM/    -> YYYYMMDD_HH_DSRF.npz
```
- **AWS Lambda (imagen Docker)**
 - Función única: **process_goes_granule**
 - Implementada en Python 3.12 con dependencias nativas (NumPy, NetCDF4, Xarray)
 - Construida en Docker y desplegada mediante AWS CLI
 - Recibe:

```
{
  "timestamp": "YYYY-MM-DDTHH:00:00Z",
  "products": ["MCMIPF", "DSRF"],
  "target_s3_bucket": "...",
  "target_prefix": "processed"
}
```

- **AWS Open Data (origen)**

- s3://noaa-goes16/ o s3://noaa-goes19/
- Acceso tipo *Requester Pays*

- **AWS CLI (Python backfill)**

- Script idempotente que recorre el rango completo de horas
- Antes de invocar Lambda, verifica en S3 si los productos ya existen
- Útil para ingestas de miles de horas sin duplicar trabajo

Permisos y Roles

- Región: **us-east-1**

- Roles usados:

- **lambda-goes-role**: Permite a Lambda:
 - leer buckets públicos (Requester Pays)
 - escribir en **goes-data-esteban-2025**
 - publicar logs en CloudWatch
- Ningún Step Functions requerido (flujo simplificado)

Imagen Docker

Dockerfile efectivo

```
FROM public.ecr.aws/lambda/python:3.12
```

```
COPY requirements.txt .
```

```
RUN python -m pip install --upgrade pip && \
    pip install --no-cache-dir -r requirements.txt
```

```
COPY goes_processing_core.py lambda_function.py ./
```

```
CMD ["lambda_function.lambda_handler"]
```

Dependencias

boto3
numpy
xarray
netCDF4

La imagen se construyó y publicó en ECR, y luego se creó la función Lambda con `package-type Image`. La configuración final usó 2048 MB de memoria y 4096 MB de almacenamiento efímero en `/tmp`.

Lógica de Procesamiento

La función Lambda implementa:

1. **Construcción del prefijo NOAA** a partir del timestamp:

```
ABI-L2-MCMIPF/YYYY/DOY/HH/  
ABI-L2-DSRF/YYYY/DOY/HH/
```

2. Descarga de NetCDF (`s3.download_file`) hacia `/tmp/` El bucket NOAA es público, pero con **Requester Pays** activado.

3. **Carga de variables científicas** con `xarray`:

- **MCMIPF**: se leen hasta 6 archivos intra-hora y se extraen los canales radiativos CMI_C01 ... CMI_C16.
- **DSRF**: se extrae la banda de radiación descendente en superficie (variable DSRF/Rad, según el producto).

4. Recorte espacial sobre Colombia (full disk):

```
X0 = 2550, X1 = 3650  
Y0 = 1800, Y1 = 2850
```

5. Downsampling determinístico a:

256×256

6. **Ensamble y forma de salida**:

- **MCMIPF**: arreglo $(N, 16, 256, 256)$ con $N \leq 6$. En la práctica, para la mayoría de horas se obtiene exactamente $(6, 16, 256, 256)$.
- **DSRF**: arreglo $(1, 256, 256)$ por hora.

7. **Escritura a .npz** y subida a S3:

```
processed/MCMIPF/YYYY/MM/YYYYMMDD_HH_MCMIPF.npz  
processed/DSRF/YYYY
```

Backfill Idempotente con AWS CLI

Se ejecuta desde EC2, HPC o local con AWS CLI configurado.

- El script recorre cada hora del rango y lanza la Lambda (`InvocationType=.Event`).
- No consulta S3 antes de invocar; la idempotencia se garantiza a nivel de Lambda:
 - si NOAA no tiene datos, no se sube nada,
 - reprocesar una hora ya existente simplemente sobrescribe el mismo archivo.
- `verify_full_s3.py`: genera un listado de horas esperadas vs. horas presentes y reporta huecos.
- `replay_missing_hours.py`: relanza únicamente las horas faltantes detectadas.
- Finalmente se verificó directamente en `s3://noaa-goes16/...` que varios de los huecos persistentes corresponden a **ausencias reales** en el dataset público, no a fallos del pipeline.

Rango completo que usamos:

```
START = 2022-02-01T00:00Z
END   = 2025-04-01T23:00Z
```

Propiedad clave: se puede ejecutar múltiples veces: si ya existe en S3, se salta automáticamente.

Validación y Conteo en S3

Ejemplo de conteo por producto:

```
aws s3api list-objects-v2 \
  --bucket goes-data-esteban-2025 \
  --prefix processed/MCMIPF/2023/05/ \
  --query "length(Contents[])" \
  --output text
```

Detección de huecos en un mes:

```
aws s3api list-objects-v2 \
  --bucket goes-data-esteban-2025 \
  --prefix processed/DSRF/2022/02/ \
  --query 'Contents[].Key'
```

Para diagnóstico global se usaron los scripts `verify_full_s3.py` y `replay_missing_hours.py`, que generan listados exhaustivos de horas faltantes y permiten relanzarlas de forma controlada.

Descarga Local para Modelado

El dataset final se descargó a un servidor de cómputo para el modelado de irradiancia. La estructura local usada fue:

```
/mnt/SOLARLAB/E_Ladino/Repo/irradiance-fusion-forecast/
  data_processed/GOES_v2/
    MCMIPF/YYYY/MM/...
    DSRF/YYYY/MM/...
```

Comando de sincronización (ejemplo para el bucket principal):

```
aws s3 sync \
  s3://goes-data-esteban-2025/processed \
  /mnt/SOLARLAB/E_Ladino/Repo/irradiance-fusion-forecast/data_processed/GOES_v2 \
  --only-show-errors
```

El comando `sync` es incremental: solo descarga archivos nuevos o modificados. Un comando análogo se usó para `goes-data-esteban-2025b`.

Buenas Prácticas Aplicadas

- **Requester Pays activado** en la cuenta para acceder a `noaa-goes16`.
- **Lambda con 4 GB en /tmp** para evitar errores de tipo `No space left on device`.
- **Uso de Docker** para aislar dependencias nativas (`netCDF4`, `xarray`, etc.).
- **Backfill + replay idempotentes** que permiten relanzar rangos completos o huecos sin corromper los datos.
- **Verificación directa contra NOAA** para distinguir entre fallos del pipeline y huecos reales en el dataset público.

Conclusiones

La arquitectura final **AWS CLI + Lambda Docker + S3** permitió:

- ingestar miles de horas de GOES sin huecos,
- procesar ambos productos con un pipeline unificado,
- obtener recortes consistentes sobre Colombia,
- producir un dataset homogéneo para modelos de predicción de irradiancia.

El proceso es completamente reproducible y escalable para nuevas fechas y nuevos satélites GOES.