



Modelo de predicción multifuente para irradiancia solar mediante aprendizaje profundo, análisis de imagen y datos satelitales en Colombia

Esteban Ladino Nieto

Facultad de Ingeniería
Departamento de Ingeniería mecánica
Bogotá, Colombia
23 de febrero de 2026

Modelo de predicción multifuente para irradiancia solar mediante aprendizaje profundo, análisis de imagen y datos satelitales en Colombia

Esteban Ladino Nieto

Tesis presentada como requisito para optar al título de:
Ingeniero Mecánico

Director:

Dr. Andrés González Mancera
Director - Departamento de Ingeniería mecánica
Facultad de Ingeniería
Universidad de los Andes

Agradecimientos

Agradezco en primer lugar a mi familia, y de manera muy especial a mis padres, por su apoyo incondicional, paciencia y confianza a lo largo de mi formación académica. Su ejemplo, esfuerzo y dedicación han sido el motor que me impulsa a alcanzar cada meta, incluso en los momentos más exigentes de este camino.

A mis amigos, por estar presentes en cada etapa, ofrecer palabras de ánimo, escuchar y compartir tanto los desafíos como los logros. Su compañía ha sido un apoyo emocional invaluable y un recordatorio constante de la importancia de disfrutar el proceso.

A mi asesor, el profesor Andrés González Mancera, por su guía, dedicación y valiosas recomendaciones en el desarrollo de este proyecto. Su experiencia y orientación han sido fundamentales para encaminar esta investigación hacia un enfoque sólido y pertinente. y con proyección práctica.

Finalmente, a la Universidad de los Andes y al Departamento de Ingeniería Mecánica por brindar el espacio, las herramientas y el acompañamiento académico que han hecho posible el avance y consolidación de este trabajo así como de mi formación.

Resumen y Abstract

Este trabajo desarrolla modelos de pronóstico intradiario de la irradiancia global horizontal (GHI) con un horizonte de 60 minutos ($H=6$, datos cada 10 minutos) para una estación terrestre en Bogotá. Se implementan dos rutas de modelado: una basada en variables tabulares, que incluye modelos MLP y arquitecturas secuenciales (LSTM, BiLSTM, CNN LSTM y un Transformer compacto), y una ruta satelital que emplea productos GOES ABI L2, específicamente DSRF y MCMIPF, adquiridos de forma automática mediante infraestructura en AWS. A partir de estas modalidades se proponen también modelos de fusión que integran información tabular con imágenes satelitales.

Los modelos se evaluaron frente a un esquema de persistencia empleando RMSE, MAE, R^2 y skill. La optimización de hiperparámetros se ejecutó con Optuna y almacenamiento JournalStorage, mientras que el rastreo de experimentos se realizó con MLflow para garantizar reproducibilidad. Los resultados muestran que los modelos tabulares ofrecen un desempeño notable y que los modelos satelitales puros presentan capacidades predictivas limitadas en ausencia de información local. La fusión multifuente, en particular la integración de MCMIPF con datos tabulares, logra el mejor desempeño global con reducciones de error superiores al 30 por ciento frente a la persistencia y una mayor estabilidad en condiciones de nubosidad variable.

Palabras clave: Transición energética, predicción solar, irradiancia, aprendizaje profundo, series temporales, datos satelitales, fusión multifuente.

This thesis develops intraday forecasting models for global horizontal irradiance (GHI) with a 60 minute horizon ($H=6$, 10 minute resolution) at a ground station in Bogotá. Two modeling tracks are implemented: a tabular track that includes MLPs and sequential architectures (LSTM, BiLSTM, CNN LSTM, and a compact Transformer), and a satellite based track using GOES ABI L2 products, specifically DSRF and MCMIPF, automatically ingested through an AWS data pipeline. Multisource fusion models that integrate tabular predictors with satellite imagery are also proposed.

Models are benchmarked against a persistence baseline using RMSE, MAE, R^2 , and skill. Hyperparameter optimization is performed with Optuna and JournalStorage, and experiment tracking is handled with MLflow to ensure reproducibility. Results show that tabular models achieve strong performance and that satellite only models are limited when local surface information is absent. Multisource fusion, particularly the combination of MCMIPF with tabular inputs, achieves the best overall performance with error reductions above 30 percent relative to persistence and improved stability under variable cloud conditions.

Keywords: Energy transition, solar forecasting, irradiance, deep learning, time series, satellite data, multisource fusion.

Índice general

Resumen y Abstract	4
Indice de figuras	7
Indice de tablas	8
Introducción	9
Objetivos	12
Objetivo general	12
Objetivos específicos	12
Metodología	13
Caso de estudio y fuentes de datos	13
Construcción del dataset tabular	16
Procesamiento de imágenes satelitales	18
Modelos predictivos	19
Entrenamiento, validación y métricas	21
Resultados	23
Modelos tabulares	23
Modelos satelitales y de fusión	30
Resumen	37
Discusión	39
Conclusión	44
Referencias	46
Anexos	48
Enlace a repositorio	48
Instructivo para la Descarga del Producto GOES – DSRF en AWS	48

Índice de figuras

1.	Ejemplo de imagen de disco completo de GOES-16 (producto MCMIPF) con área de interés sobre Colombia.	14
2.	Ejemplo de recorte de DSRF sobre el área de interés.	15
3.	Recorte del producto MCMIPF sobre el área de interés.	15
4.	Flujo de construcción del dataset tabular.	16
5.	Estructura general de una celda LSTM.	19
6.	Esquema de una red BiLSTM.	20
7.	Skill frente a la persistencia por hora del día para los modelos tabulares en el conjunto de prueba.	25
8.	Serie temporal del modelo MLP en el conjunto de prueba.	26
9.	Serie temporal del modelo LSTM en el conjunto de prueba.	26
10.	Serie temporal del modelo BiLSTM en el conjunto de prueba.	26
11.	Serie temporal del modelo Transformer en el conjunto de prueba.	27
12.	Serie temporal del modelo CNN LSTM en el conjunto de prueba.	27
13.	Error RMSE del MLP segmentado por rangos de irradiancia real.	27
14.	Mapas hora–horizonte de RMSE para los modelos tabulares.	28
15.	Mapas hora–horizonte de skill frente a la persistencia para los modelos tabulares.	29
16.	Desempeño del modelo ConvLSTM solo DSRF en el conjunto de prueba.	31
17.	Desempeño del modelo CNN LSTM solo MCMIPF en el conjunto de prueba.	32
18.	Residuales del modelo ConvLSTM solo DSRF.	33
19.	Residuales del modelo CNN LSTM solo MCMIPF.	33
20.	Skill horario frente a persistencia del modelo ConvLSTM solo DSRF.	33
21.	Skill horario frente a persistencia del modelo CNN LSTM solo MCMIPF.	34
22.	Desempeño del modelo de fusión DSRF + tabular en el conjunto de prueba.	35
23.	Desempeño del modelo de fusión MCMIPF + tabular en el conjunto de prueba.	36
24.	Residuales del modelo de fusión DSRF + tabular.	36
25.	Residuales del modelo de fusión MCMIPF + tabular.	37
26.	Skill horario frente a persistencia para los modelos híbridos satélite + tabular.	37

Índice de tablas

1.	Normatividad y estándares aplicables a la energía solar en Colombia	11
2.	Desempeño de modelos tabulares y secuenciales basados en datos de superficie en el conjunto de prueba ($H = 60$ min).	23
3.	Hiperparámetros óptimos obtenidos mediante búsqueda con Optuna.	24
4.	Desempeño de modelos satelitales y de fusión para $H = 60$ min en el conjunto de prueba.	30

Introducción

La transición energética global ha impulsado una expansión acelerada de las fuentes renovables como respuesta a los impactos ambientales derivados del uso intensivo de combustibles fósiles. A nivel mundial se emiten alrededor de 8 mil millones de toneladas de carbono al año, de las cuales 6,5 mil millones provienen del consumo de hidrocarburos y 1,5 mil millones de procesos de deforestación; proyecciones recientes advierten consecuencias climáticas irreversibles si esta tendencia persiste [1]. Frente a este panorama, la energía solar fotovoltaica se ha consolidado como una tecnología estratégica debido a su baja huella de carbono, disponibilidad y madurez tecnológica.

En Colombia, la adopción de energías renovables no convencionales ha sido fomentada por la Ley 1715 de 2014, que estableció incentivos tributarios y un marco institucional que ha habilitado la rápida expansión de proyectos solares. La dinámica reciente es notable: en 2024 ingresaron 63 proyectos solares al Sistema Interconectado Nacional (SIN), sumando alrededor de 1,4 GW de nueva capacidad [2], y para el primer trimestre de 2025 el país se aproxima a los 2 GW instalados [3]. Proyecciones de la UPME plantean un horizonte cercano a 6 GW hacia 2026 [4], en línea con las metas del “Plan 6 GW”. Este crecimiento, con tasas superiores al 60 % anual en algunos periodos [5], exige capacidades robustas de pronóstico para respaldar la integración solar en la operación del sistema.

Mercado eléctrico colombiano y necesidad de pronóstico

El mercado eléctrico colombiano opera bajo una regulación a cargo de la Comisión de Regulación de Energía y Gas (CREG) y una administración operativa realizada por XM. En este esquema, generadores y comercializadores deben presentar ofertas de generación con 24 horas de anticipación en el mercado *day-ahead* [6], [7]. Para tecnologías solares, la precisión del pronóstico horario de irradiancia y energía es crucial: desviaciones significativas entre la energía ofertada y la efectivamente inyectada generan penalizaciones económicas.

La expansión de la generación distribuida, habilitada por resoluciones como la CREG 174 de 2021 y la CREG 135 de 2021, ha añadido aún mayor relevancia al pronóstico solar a corto plazo. Esquemas como el *Programa Colombia Solar* incentivan la instalación de sistemas FV en pequeñas empresas y hogares, aumentando la necesidad de estimaciones confiables de irradiancia tanto para operación local como para interacción con la red [8].

Estas dinámicas revelan un punto crítico: la operación del sector eléctrico colombiano depende cada vez más de pronósticos precisos de irradiancia global horizontal (GHI), especialmente en horizontes intradiarios.

Desafíos técnicos del pronóstico solar

La predicción de GHI a corto plazo es un problema complejo debido a la marcada variabilidad atmosférica. Cambios abruptos en la cobertura nubosa modulan la irradiancia en escalas de minutos, afectando la generación FV e introduciendo incertidumbre operativa. Modelos físicos de predicción numérica del tiempo, como el *Global Forecast System* (GFS), presentan limitaciones de resolución espacial y desempeño subóptimo en climas tropicales, especialmente en regiones andinas y de sabana como Bogotá.

Frente a estas limitaciones, han ganado relevancia enfoques basados en datos (*data-driven*) que aprovechan mediciones locales de alta frecuencia y productos remotos como los provenientes de satélites geoestacionarios. La combinación de estas fuentes es especialmente prometedora: los datos tabulares locales capturan la señal puntual con alta fidelidad, mientras que las imágenes satelitales aportan información espacial sobre la estructura y desplazamiento de nubes.

Integrar ambas fuentes no es trivial. Existen retos asociados a la sincronización de resoluciones temporales, manejo de grandes volúmenes de datos satelitales, definición del vecindario espacial relevante y diseño de arquitecturas capaces de procesar simultáneamente datos tabulares e imágenes. La literatura reciente destaca el potencial de arquitecturas híbridas (CNN–LSTM, ConvLSTM, Transformers ligeros) para capturar estructuras espacio-temporales, pero aún existe poca evidencia sistemática en contextos tropicales como el colombiano [9].

Motivación y propósito del proyecto

Este trabajo surge precisamente de esa necesidad. Su propósito es evaluar, en detalle, la contribución relativa de distintas fuentes de información y familias de modelos al pronóstico intradiario de irradiancia en un entorno representativo del clima tropical de sabana (Bogotá).

El proyecto se orienta a evaluar el aporte relativo de cada fuente de información y de cada familia de modelos al pronóstico intradiario de la irradiancia. En primer lugar, se examina el potencial de un esquema puramente tabular construido a partir de mediciones locales, retardos de corto plazo, agregados móviles y variables astronómicas, empleando tanto modelos MLP como arquitecturas secuenciales del tipo LSTM, BiLSTM, CNN–LSTM y Transformers ligeros. Este camino permite establecer el límite práctico alcanzable cuando únicamente se dispone de datos de superficie.

De manera complementaria, se analiza el valor añadido de la información satelital proporcionada por GOES–16, experimentando con modelos que operan exclusivamente sobre imágenes, como ConvLSTM para el producto DSRF y CNN–LSTM para el mosaico multicanal MCMIPF. Estas arquitecturas buscan capturar la estructura espacial y la evolución temporal de la nubosidad en el vecindario de Bogotá, proporcionando un contexto que las mediciones puntuales no contienen.

Finalmente, se desarrollan modelos de fusión multifuente que combinan explícitamente un encoder tabular con un encoder satelital, con el propósito de integrar en un solo modelo la fidelidad local de las mediciones in situ y el contexto espacial capturado por el satélite. Estas arquitecturas híbridas permiten cuantificar de manera directa si la integración de ambas fuentes mejora la capacidad de anticipar transiciones nubosas y reduce los errores característicos de los regímenes de alta variabilidad atmosférica.

El horizonte de 60 minutos ($H = 6$ intervalos de 10 minutos) se selecciona por su relevancia operativa: permite anticipar transiciones nubosas con suficiente antelación para decisiones de operación, mitigación de desvíos y ajuste de estrategias de mercado.

Normatividad, regulaciones y estándares (nacional e internacional)

Cuadro 1: Normatividad y estándares aplicables a la energía solar en Colombia

Norma / Entidad	Descripción / Alcance
Ley 1715 de 2014	Marco legal para integrar las FNCER al sistema energético, contempla incentivos tributarios y fomenta proyectos FV.
UPME	Planeación energética nacional, registro de proyectos y lineamientos técnicos.
CREG	Regulación del sector eléctrico: conexión a red, tarifas, supervisión del mercado.
Ministerio de Minas y Energía	Política energética nacional y lineamientos de transición energética.
IEC 61724	Estándares internacionales de monitoreo solar: medición de irradiancia y aseguramiento de calidad.
WMO / OMM	Estándares meteorológicos y protocolos de calibración y medición en instrumentación solar.

Objetivos

Objetivo general

Desarrollar, validar y comparar modelos de predicción intradiaria de la *irradiancia global horizontal* (GHI) en Bogotá (Universidad de los Andes) mediante un enfoque multifuente que integra datos de superficie, geometría solar e información satelital *GOES* (productos DSRF y MCMIPF), utilizando arquitecturas de aprendizaje profundo capaces de capturar tanto la dinámica temporal como la estructura espacial asociada a la nubosidad.

Objetivos específicos

- Implementar un *pipeline* reproducible de control de calidad y modelado a partir de mediciones in situ en la estación de la Universidad de los Andes.
- Diseñar un conjunto de características tabulares que combine meteorología local, memoria temporal (*lags* y estadísticas móviles), geometría solar y transformaciones físicas relevantes.
- Construir y entrenar modelos basados en secuencias para predicción a 60 minutos, incluyendo redes LSTM, BiLSTM, CNN-LSTM y Transformers ligeros.
- Procesar productos satelitales GOES:
 - **DSRF**: señales de radiación solar descendente en superficie.
 - **MCMIPF**: mosaicos multicanal.

generando secuencias espacio-temporales alineadas y normalizadas.

- Integrar información satelital y tabular mediante arquitecturas de **fusión multifuente** basadas en ConvLSTM, CNN-LSTM y ramas duales con LSTM para capturar simultáneamente estructura espacial y dinámica temporal.
- Evaluar el desempeño de todos los modelos usando RMSE, MAE, R^2 y *skill score* respecto a persistencia, analizando sensibilidad por hora del día y comportamiento en regímenes nubosos.

Metodología

La metodología se estructura en cuatro componentes que abarcan el ciclo completo del pronóstico de irradiancia con integración satelital: (i) el caso de estudio y las fuentes de datos disponibles en la estación de superficie; (ii) la construcción del *dataset* tabular mediante control de calidad, armonización temporal e ingeniería de características; (iii) la preparación de los productos satelitales DSRF y MCMIPF y su alineación temporal con la serie terrestre; (iv) el diseño, entrenamiento y validación de las arquitecturas predictivas, que incluyen modelos tabulares, modelos secuenciales, modelos basados únicamente en imágenes y modelos de fusión multifuente.

En todo el proceso se privilegia la reproducibilidad, la causalidad temporal (evitar *look-ahead bias*) y la comparabilidad entre arquitecturas bajo un mismo protocolo experimental.

Caso de estudio y fuentes de datos

El caso de estudio corresponde al pronóstico a corto plazo de la irradiancia global horizontal (GHI) en la estación meteorológica ubicada en el campus de la Universidad de los Andes, en Bogotá. Esta estación registra variables meteorológicas con resolución uniforme de diez minutos. El objetivo es predecir el valor de GHI con sesenta minutos de anticipación, un horizonte relevante para la operación de sistemas fotovoltaicos y la caracterización de la variabilidad atmosférica en zonas andinas.

Datos de superficie

Las mediciones disponibles incluyen:

- Irradiancia global horizontal [W m^{-2}].
- Temperatura ambiente.
- Humedad relativa.
- Presión atmosférica.
- Velocidad y dirección del viento.

Estas variables caracterizan el estado local de la atmósfera e incorporan información sobre estabilidad térmica, nubosidad y dinámica del viento. A partir de ellas se construyen retardos, estadísticas móviles y transformaciones físicas que alimentan los modelos tabulares y secuenciales.

Productos satelitales (GOES-16)

Para capturar el contexto espacial de nubosidad y radiación se integran productos del satélite geoestacionario GOES-16, parte del programa GOES de NOAA. Desde su órbita fija, GOES-16 monitorea de forma continua la atmósfera sobre el continente americano, proporcionando imágenes de alta frecuencia que permiten seguir la evolución de sistemas nubosos y sus impactos sobre la irradiancia en superficie. NASA construye y lanza los satélites, mientras NOAA los opera y distribuye sus datos.

El sensor principal, el *Advanced Baseline Imager* (ABI), adquiere imágenes en 16 bandas espectrales (visibles, infrarrojas cercanas e infrarrojas térmicas) con resoluciones de 0.5 a 2 km y una frecuencia de hasta 10 minutos.[10] La Figura 1 muestra un ejemplo de imagen de disco completo.




Figura 1: Ejemplo de imagen de disco completo de GOES-16 (producto MCMIPF) con área de interés sobre Colombia.

En este trabajo se utilizan dos familias de productos derivados de ABI:

- **DSRF (Downward Shortwave Radiation at the Surface).** Estimaciones de la radiación de onda corta descendente en superficie, construidas a partir de los canales visibles e infrarrojos de ABI, el albedo de superficie y la composición atmosférica.[11] Este producto aproxima directamente la GHI y proporciona mapas de irradiancia sobre el dominio continental. Para el presente estudio se recorta un parche fijo centrado en Colombia (Figura 2), que se utiliza tanto en modelos puramente satelitales como en arquitecturas de fusión.




Figura 2: Ejemplo de recorte de DSRF sobre el área de interés.

- **MCMIPF (Cloud and Moisture Imagery, Full Disk).** Composición multicanal de ABI con 16 bandas y resolución típica de 2 km cada 10 minutos, que caracteriza cobertura y tipo de nubes, vapor de agua y propiedades de superficie.[12] A partir de este producto se construyen secuencias multicanal en una región de 256×256 píxeles centrada en Colombia (Figura 3), que se transforman luego en entradas de menor tamaño para los modelos basados en CNN.




Figura 3: Recorte del producto MCMIPF sobre el área de interés.

Los productos DSRF y MCMIPF se procesan de forma sistemática para el periodo de estudio mediante una tubería desplegada en AWS (ingesta desde los *buckets* públicos de NOAA, recorte de área de interés y almacenamiento en formato comprimido). Los detalles operativos

de esta implementación se documentan en los anexos técnicos; aquí se considera únicamente el resultado de dicho flujo: secuencias de parches satelitales alineados temporalmente con las mediciones en la estación de superficie.

Construcción del dataset tabular




Figura 4: Flujo de construcción del dataset tabular.

La construcción del *dataset* tabular se implementa en Python mediante un flujo reproducible basado en **pandas**, **NumPy** y la biblioteca **pvlib**. El objetivo es obtener una serie multivariable limpia, físicamente consistente y regular a 10 minutos, sobre la cual formular el problema de pronóstico como una tarea de regresión supervisada.

Armonización temporal

Todos los registros se convierten a la zona horaria local y se remuestrean a intervalos uniformes de diez minutos. Este paso elimina duplicados, corrige pequeñas desalineaciones horarias y garantiza que los modelos secuenciales reciban ventanas completas. La misma malla temporal se utiliza posteriormente para alinear las imágenes satelitales.

Control de calidad físico

Se aplican criterios conservadores basados en límites físicos y rangos operacionales de los sensores, entre ellos:

- GHI no negativa y acotada a un máximo de 1400 W m^{-2} .
- Velocidad de viento no negativa y acotada a valores razonables para la altitud de Bogotá.
- Presión atmosférica dentro de un rango coherente con la cota del sitio.
- Valores positivos de irradiancia nocturna corregidos a cero.

Los faltantes se imputan únicamente en variables predictoras, mediante estadísticas robustas (por ejemplo, mediana condicionada), y nunca en el objetivo GHI para evitar fuga de información.

Modelo de cielo despejado e índice de cielo despejado

Se calcula la irradiancia teórica de cielo despejado mediante el modelo de Ineichen implementado en `pvl`. A partir de este valor se obtiene el índice de cielo despejado:

$$k_{ghi}(t) = \frac{GHI(t)}{GHI_{cs}(t)},$$

El índice elimina la dependencia determinística con la posición solar y convierte el problema en uno centrado en nubosidad.. El índice k_{ghi} tiende a estabilizar el aprendizaje y facilita la comparación entre distintas épocas del año.

Ingeniería de características

Sobre la serie regularizada se construyen capas adicionales de información derivada, siguiendo principios similares a los aplicados en otros trabajos de pronóstico solar, pero adaptados al contexto de Bogotá y al horizonte de 60 minutos:

- **Variables temporales.** Hora local, día de la semana, mes e indicadores de fin de semana. Para capturar la periodicidad diaria y estacional se emplean codificaciones cíclicas seno/coseno de hora del día y día del año.
- **Descriptores astronómicos.** Empleando `pvl` se calcula la posición solar (cenit, acimut, elevación), la irradiancia extraterrestre teórica y se aprovecha el índice de cielo despejado k_{ghi} . Estas variables permiten separar efectos puramente geométricos de la variabilidad debida a nubes.
- **Estadísticas móviles y retardos.** Se generan medias y desviaciones móviles de GHI, temperatura, presión y velocidad del viento en ventanas de 60 minutos, así como retardos (lags) del objetivo y de algunas variables claves (por ejemplo, 10, 20 y 30 minutos). Se incluyen también descriptores de variabilidad de corto plazo como cambios absolutos y tasas de cambio.

Todas las variables continuas se estandarizan mediante un `StandardScaler` ajustado exclusivamente sobre el subconjunto de entrenamiento. El objetivo GHI se trabaja en unidades físicas y se revierte al espacio original para el cálculo de métricas.

Formulación secuencial del problema

El pronóstico de corto plazo se formula como un problema de regresión sobre series temporales con ventanas deslizantes. Dada una longitud de ventana L (en pasos de 10 minutos) y un horizonte de pronóstico H , cada muestra de entrenamiento se construye como:

$$\mathbf{X}_{t-L+1:t} \in \mathbb{R}^{L \times D}, \quad y_{t+H} \in \mathbb{R},$$

donde D es el número de *features* tabulares por paso de tiempo y y_{t+H} corresponde a la GHI en el horizonte elegido ($H = 6$ para 60 minutos). La generación de ventanas se realiza de forma estrictamente causal y respetando el orden temporal, evitando cualquier uso de información futura.

Las particiones de entrenamiento, validación y prueba se construyen como segmentos temporales no solapados. El conjunto de prueba se reserva para los últimos meses del periodo de estudio y no participa en la optimización de hiperparámetros; la validación se utiliza exclusivamente para selección de modelos y *early stopping*.

Procesamiento de imágenes satelitales

Ingesta y alineación temporal

Los archivos NetCDF correspondientes a DSRF y MCMIPF se descargan desde los repositorios públicos de NOAA utilizando una tubería automatizada desplegada en AWS. Una vez almacenados en S3, se procesan localmente: se filtran las fechas de interés, se extrae la subregión geográfica que contiene a Colombia y se proyectan las coordenadas a un sistema común.

Las marcas temporales de las imágenes se armonizan con la serie de la estación, remuestreando o seleccionando el fotograma más cercano para obtener series uniforme a 10 minutos. De este modo, cada *timestamp* dispone de un vector de características tabulares y, cuando hay cobertura satelital, de los parches correspondientes de DSRF y MCMIPF.

DSRF

Para cada imagen DSRF se carga la matriz de radiación, se extrae el recorte centrado en el área de interés y se remuestrea a un tamaño reducido (por ejemplo, 32×32 píxeles con un canal). La normalización se realiza de forma global utilizando la media y desviación estándar del conjunto de entrenamiento. Las imágenes resultantes se almacenan como tensores 3D y posteriormente se ensamblan en secuencias temporales para los modelos.

MCMIPF

El producto MCMIPF proporciona hasta seis fotogramas por hora en 16 canales. El procesamiento consiste en:

- Selección de un subconjunto de bandas relevantes (visibles, infrarrojas cercanas e infrarrojas térmicas).
- Remuestreo de cada fotograma a 32×32 píxeles.
- Normalización independiente por canal (media cero, desviación unitaria sobre el entrenamiento).
- Construcción de secuencias espacio-temporales con forma (L, H, W, C) alineadas con las ventanas tabulares.

Estas secuencias se utilizan tanto en modelos satelitales puros como en la rama satelital de los modelos de fusión.

Modelos predictivos

Los modelos se agrupan en cuatro familias complementarias: modelos tabulares no secuenciales, modelos tabulares secuenciales, modelos basados exclusivamente en imágenes satelitales y modelos de fusión multifuente.

Modelos tabulares

Como línea base tabular se emplea una red densa MLP que recibe, para cada muestra, el vector de características correspondiente al instante t (o a un resumen de la ventana $t - L + 1 : t$). Esta arquitectura permite establecer un piso de desempeño para modelos sin memoria explícita.

Sobre la formulación secuencial se implementan además arquitecturas LSTM, BiLSTM, CNN-LSTM y un Transformer ligero, que operan directamente sobre ventanas (L, D) :

- **LSTM y BiLSTM.** Redes recurrentes capaces de modelar dependencias temporales de corto y mediano plazo. La versión bidireccional se utiliza únicamente durante el entrenamiento, preservando la causalidad en la configuración final.
- **CNN-LSTM.** Bloques convolucionales 1D extraen patrones locales sobre el eje temporal (por ejemplo, transiciones abruptas de nubosidad), y sus salidas se alimentan a una LSTM que modela dependencias de mayor escala.
- **Transformer ligero.** Un codificador basado en mecanismos de atención aplica auto-atención sobre la secuencia, seguido de una etapa de *pooling* temporal y capas densas finales.

La Figura 5 presenta la estructura general de una celda LSTM, mientras que la Figura 6 ilustra el esquema de una red BiLSTM.




Figura 5: Estructura general de una celda LSTM.




Figura 6: Esquema de una red BiLSTM.

Modelos basados en imágenes satelitales

Para evaluar la capacidad predictiva intrínseca de los productos satelitales se consideran dos arquitecturas que operan exclusivamente con imágenes:

- **ConvLSTM sobre DSRF.** Secuencias de longitud L de parches DSRF de tamaño reducido se procesan mediante una o dos capas ConvLSTM2D, seguidas de capas de normalización, *dropout* espacial y *Global Average Pooling*. Una capa densa final proyecta el embedding resultante a una única predicción de GHI a 60 minutos.
- **CNN-LSTM sobre MCMIPF.** Cada fotograma (H, W, C) se procesa con una CNN ligera (*Conv-BatchNorm-Pooling*), resumida mediante *Global Average Pooling* en un vector latente. Mediante una capa **TimeDistributed**, la CNN se aplica a cada fotograma de la secuencia, y la serie resultante de embeddings se alimenta a una LSTM temporal. Las salidas de la LSTM se conectan a una cabeza densa que produce la predicción de GHI.

Estos modelos permiten cuantificar qué fracción de la variabilidad de la irradiancia puede explicarse únicamente desde la información espacial y espectral capturada por GOES-16, sin recurrir a mediciones locales.

Modelos de fusión multifuente

Finalmente se desarrollan modelos híbridos que combinan explícitamente información tabular y satelital. La idea central es que la rama tabular proporcione anclaje local y memoria detallada de la serie en la estación, mientras que la rama satelital aporte contexto espacial sobre la estructura y el movimiento de nubes.

El esquema general es el siguiente:

- **Rama tabular.** La ventana temporal (L, D) se procesa con un MLP o una LSTM, obteniendo un embedding de dimensión fija que resume la dinámica local.

- **Rama satelital.** Secuencias de parches DSRF o MCMIPF se procesan con un ConvLSTM o un bloque CNN–LSTM, generando un vector que condensa la información espacio-temporal en el entorno de Bogotá.
- **Fusión y salida.** Los embeddings de ambas ramas se concatenan y se pasan por una o dos capas densas intermedias con activación no lineal y *dropout*. Una neurona de salida estima la GHI en el horizonte $H = 6$.

Este esquema permite comparar, bajo un mismo protocolo experimental, el aporte relativo de los productos DSRF y MCMIPF cuando se integran con la información tabular de superficie.

Entrenamiento, validación y métricas

Todos los modelos se entrenan minimizando el error cuadrático medio (MSE) entre la irradiancia observada y la irradiancia pronosticada a 60 minutos. Se utiliza el optimizador Adam con tasas de aprendizaje en el rango 10^{-4} – 10^{-3} según la arquitectura, junto con técnicas de estabilización como *gradient clipping* (norma máxima acotada), *EarlyStopping* con restauración del mejor modelo en validación y *ReduceLROnPlateau* para disminuir automáticamente la tasa de aprendizaje en presencia de estancamiento.

Las particiones de entrenamiento, validación y prueba se definen estrictamente en orden temporal para evitar *look-ahead bias*. El conjunto de prueba se reserva por completo y no se utiliza durante la búsqueda de hiperparámetros. Todas las corridas fijan semillas aleatorias en Python, NumPy y TensorFlow, y se registran versiones de librerías y configuraciones relevantes. Para asegurar compatibilidad con Keras 3, los modelos se definen mediante constructores (*builders*) serializables y se almacenan únicamente sus pesos, evitando problemas de deserialización con capas anónimas.

La evaluación cuantitativa se realiza mediante:

- raíz del error cuadrático medio (RMSE),
- error absoluto medio (MAE),
- coeficiente de determinación (R^2),
- *skill score* frente a la persistencia, definido como

$$\text{Skill} = 1 - \frac{\text{RMSE}_{\text{modelo}}}{\text{RMSE}_{\text{persistencia}}}.$$

Adicionalmente se emplean herramientas diagnósticas como gráficos de paridad, distribuciones de residuales, series temporales comparadas modelo–observación, mapas hora–horizonte y segmentación del error por rangos de irradiancia.

Optimización de hiperparámetros con Optuna

La selección de hiperparámetros se sistematiza mediante Optuna, empleando el algoritmo *Tree-structured Parzen Estimator* (TPE) y *pruning* basado en mediana para detener ensayos no prometedores. La búsqueda se registra en un almacenamiento tipo *JournalStorage*, lo que permite tolerancia a fallos y ejecución reproducible.

El espacio de búsqueda depende de la arquitectura e incluye, entre otros:

- Dimensión de capas densas u ocultas (64–320 unidades).
- Número de capas recurrentes (1–2) y filtros convolucionales (32–64) en los modelos CNN–LSTM.
- Tasas de *dropout* en el rango 0,05–0,50.
- Tasa de aprendizaje inicial en el rango 10^{-4} – 10^{-2} .
- Longitud de la ventana temporal L (18–24 pasos).
- Tamaño del lote (32–512).
- Penalización ℓ_2 en el rango 10^{-7} – 10^{-4} .

En el caso de los modelos satelitales, también se optimizan dimensiones de los extractores espaciales (número de filtros, tamaño de kernel, profundidad convolucional) y parámetros de la LSTM temporal asociada.

Cada combinación propuesta por Optuna se entrena utilizando el conjunto de entrenamiento y se evalúa sobre validación mediante el RMSE como métrica objetivo. Los ensayos cuyo desempeño preliminar es claramente inferior a la mediana se interrumpen de manera anticipada. Una vez identificada la mejor configuración para cada familia de modelos, se reentrena utilizando entrenamiento+validación y se reserva el conjunto de prueba exclusivamente para la evaluación final presentada en el capítulo de Resultados.

Artefactos y reproducibilidad

Para cada experimento se almacenan los artefactos principales: pesos del modelo, configuración completa de hiperparámetros, métricas de entrenamiento y validación, curvas de pérdida y figuras de diagnóstico (paridad, residuales, series temporales y mapas hora–horizonte). Los experimentos y sus metadatos se registran adicionalmente en MLflow, lo que facilita la trazabilidad entre modelos tabulares, satelitales e híbridos.

Las ejecuciones se realizan con semillas fijas y documentación explícita del entorno (CPU/GPU, versiones de TensorFlow, Optuna y bibliotecas satelitales). La combinación de almacenamiento estructurado, *JournalStorage*, MLflow y constructores serializables en Keras garantiza la reproducibilidad completa del *pipeline* desde los datos crudos hasta la evaluación final.

Resultados

Este capítulo presenta el desempeño de los modelos desarrollados para un horizonte de pronóstico de 60 minutos ($H = 6$). Se analizan dos familias principales: modelos tabulares basados en datos de superficie y modelos satelitales, incluyendo arquitecturas híbridas que combinan imágenes con secuencias tabulares. Todas las métricas se reportan sobre el conjunto de prueba, garantizando independencia respecto al entrenamiento y a la selección de hiperparámetros.

Modelos tabulares

Métricas de desempeño

La Tabla 2 resume el rendimiento de los modelos tabulares (MLP) y de las arquitecturas secuenciales basadas en ventanas temporales. El MLP es el modelo con mejor desempeño global en esta familia, con un RMSE de 135 W/m^2 y un skill de 0.31 frente a la persistencia. En términos relativos, esto implica una reducción de aproximadamente 31 % en RMSE frente al baseline, que presenta un error de 196.3 W/m^2 .

Los modelos secuenciales (LSTM, BiLSTM, CNN LSTM y Transformer) presentan un desempeño muy cercano entre sí: sus RMSE se ubican en el rango $137\text{--}140 \text{ W/m}^2$ y los skill oscilan entre 0.29 y 0.30. Todos superan de forma clara a la persistencia, con reducciones de error del orden de 29–30 %, pero ninguno logra desbancar al MLP.

Cuadro 2: Desempeño de modelos tabulares y secuenciales basados en datos de superficie en el conjunto de prueba ($H = 60 \text{ min}$).

Modelo	RMSE	MAE	R2	Skill
Persistencia	196.3	—	0.419	0.000
MLP	135.0	66.7	0.725	0.312
LSTM	137.0	71.7	0.717	0.303
BiLSTM	137.5	71.6	0.715	0.300
CNN LSTM	140.1	71.6	0.704	0.287
Transformer	139.3	71.9	0.708	0.291

El hecho de que un modelo puramente *feedforward* como el MLP supere a las arquitecturas recurrentes indica que la ingeniería de características tabulares captura ya una fracción importante de la estructura temporal relevante a 60 minutos. Las RNN añaden capacidad

de memoria explícita, pero en este horizonte la información incremental que explotan parece limitada frente a la que ya está codificada en las variables agregadas y astronómicas.

Hiperparámetros óptimos

La Tabla 3 resume los hiperparámetros seleccionados mediante búsqueda bayesiana con Optuna para cada modelo tabular y secuencial. No se observan configuraciones extremas: los tamaños de capa y número de unidades se mantienen en rangos moderados, los *batch sizes* son relativamente grandes y los *learning rates* se ubican en el orden de 10^{-3} , lo que sugiere que el problema es suficientemente informativo y no requiere arquitecturas muy profundas ni ajustes agresivos para converger.

Cuadro 3: Hiperparámetros óptimos obtenidos mediante búsqueda con Optuna.

Modelo	Hiperparámetros óptimos
MLP	$n1 = 320$, $n2 = 128$, $do1 = 0.486$, $do2 = 0.337$, $lr = 0.00376$, $l2 = 7.06e-06$, $act = gelu$, $batch = 512$, $epochs = 43$
LSTM	$seq\ len = 24$, $units = 96$, $dropout = 0.351$, $lr = 0.00196$, $batch = 64$, $epochs = 63$
BiLSTM	$seq\ len = 18$, $units = 96$, $dropout = 0.180$, $lr = 0.00419$, $batch = 128$, $epochs = 100$
CNN LSTM	$seq\ len = 18$, $filters = 64$, $kernel\ size = 2$, $pool = 1$, $lstm\ units = 128$, $dropout = 0.118$, $lr = 0.00193$, $batch = 64$, $epochs = 67$
Transformer	$seq\ len = 18$, $d\ model = 32$, $heads = 4$, $ff\ dim = 192$, $att\ dropout = 0.164$, $dropout = 0.111$, $lr = 0.00283$, $batch = 64$, $epochs = 64$

En particular, el MLP converge con apenas 43 épocas y un *batch size* alto, lo que refuerza la idea de que el espacio de hipótesis requerido para capturar la dinámica a 60 minutos no es excesivamente complejo cuando se dispone de mediciones locales y variables derivadas. En contraste, las arquitecturas secuenciales requieren más épocas (60–100) para estabilizarse, pero el beneficio marginal en métricas globales frente al MLP es limitado.

Comparación entre modelo no secuencial y modelos secuenciales

El análisis conjunto de la Tabla 2 muestra que:

- Todos los modelos tabulares reducen fuertemente el error frente a la persistencia: la mejora en RMSE se sitúa entre 28.6 % (CNN LSTM) y 31.2 % (MLP).
- Las diferencias entre LSTM, BiLSTM, CNN LSTM y Transformer son pequeñas, lo que sugiere que, dado el conjunto de variables disponibles, el límite de predictibilidad a 60 minutos está dominado por el fenómeno físico y no por la capacidad del modelo.
- El MLP ofrece el mejor compromiso entre precisión y complejidad arquitectónica, con el menor RMSE y el mayor skill, utilizando una estructura más simple y con menos supuestos sobre la dinámica temporal.

En conjunto, estos resultados indican que, bajo un esquema puramente tabular, la calidad y el diseño de las características juegan un papel tan importante como la elección de la arquitectura de red neuronal.

Skill horario frente a la persistencia

La Figura 7 muestra el skill frente a la persistencia promediado por hora del día para los cinco modelos tabulares. Se observan tres regímenes bien diferenciados:

- **Horas nocturnas (00:00–08:00).** El skill es marcadamente negativo en todos los modelos, con caídas de varias decenas de puntos porcentuales alrededor de las 08:00–09:00. En este intervalo la irradiancia real es muy baja o nula y la persistencia, que mantiene un valor cercano a cero, resulta un baseline extremadamente fuerte: cualquier desviación de los modelos neuronales se traduce en error relativo elevado.
- **Transición al día (09:00–10:00).** Se observa un mínimo pronunciado del skill en las primeras horas de la mañana, justo antes de que el sol alcance alturas significativas. Este comportamiento es consistente con un régimen de rápida transición en el que pequeños desfases temporales entre la subida real de la GHI y la subida estimada penalizan fuertemente el error cuadrático, mientras que la persistencia sigue en valores muy bajos.
- **Horas solares (10:00–17:00).** A partir de las 10:00 todas las arquitecturas pasan a skill positivo y se mantienen por encima de la persistencia durante el resto del día. En este tramo la variabilidad de la irradiancia es alta y la persistencia se vuelve un baseline pobre, de modo que los modelos aprovechan tanto las variables meteorológicas como la información astronómica para capturar la estructura intra-diaria. Las curvas de los cinco modelos se agrupan muy cerca entre sí, lo que refuerza la idea de que la limitación dominante proviene del fenómeno físico y no de la capacidad de la arquitectura.

En términos relativos, el MLP mantiene sistemáticamente el mejor skill entre las 00:00 y las 17:00, seguido muy de cerca por las arquitecturas recurrentes. CNN LSTM y Transformer tienden a comportarse ligeramente mejor que LSTM y BiLSTM en las horas centrales, pero las diferencias son pequeñas frente a la dispersión inherente del fenómeno.




Figura 7: Skill frente a la persistencia por hora del día para los modelos tabulares en el conjunto de prueba.

Visualización temporal del desempeño

Las Figuras 8 a 12 muestran el comportamiento temporal de las predicciones en el conjunto de prueba. Todos los modelos reproducen adecuadamente el ciclo diurno de la irradiancia y capturan la forma general de los picos alrededor del mediodía. Sin embargo, los errores más altos coinciden con episodios de nubosidad variable, en los cuales la irradiancia presenta cambios abruptos difíciles de anticipar con información puramente local.




Figura 8: Serie temporal del modelo MLP en el conjunto de prueba.




Figura 9: Serie temporal del modelo LSTM en el conjunto de prueba.




Figura 10: Serie temporal del modelo BiLSTM en el conjunto de prueba.




Figura 11: Serie temporal del modelo Transformer en el conjunto de prueba.




Figura 12: Serie temporal del modelo CNN LSTM en el conjunto de prueba.

La Figura 13 presenta el error del MLP por rangos de irradiancia real. El RMSE mínimo se observa en condiciones de irradiancia baja (amanecer, atardecer o cielos muy cubiertos), donde la señal es más estable. Los máximos se concentran en rangos intermedios y altos, dominados por nubosidad transitoria y por desfases temporales cercanos al máximo diario, donde pequeñas discrepancias en el tiempo producen diferencias grandes en W/m^2 .




Figura 13: Error RMSE del MLP segmentado por rangos de irradiancia real.

Estructura conjunta hora–horizonte

Para analizar cómo se degrada el desempeño con el horizonte y cómo varía con la hora del día, se construyeron mapas hora–horizonte de RMSE y de skill para cada modelo tabular (Figuras 14 y 15). Cada mapa muestra el error promedio en función de la hora local (eje horizontal) y del horizonte de pronóstico (eje vertical).




Figura 14: Mapas hora–horizonte de RMSE para los modelos tabulares.




Figura 15: Mapas hora–horizonte de skill frente a la persistencia para los modelos tabulares.

De estos mapas se desprenden varios patrones robustos:

- **Crecimiento del error con el horizonte.** Para todas las arquitecturas el RMSE aumenta conforme crece el horizonte, reflejando la pérdida de predictibilidad a medida que se aleja la ventana de pronóstico. La pendiente de este aumento es más pronunciada alrededor del mediodía, cuando la irradiancia absoluta es mayor y los errores se amplifican en W/m^2 .
- **Dependencia horaria del skill.** El skill es prácticamente nulo durante la noche para todos los horizontes, confirmando que en ausencia de irradiancia la persistencia es difícil

de superar. En horas solares el skill es positivo para horizontes cortos y se mantiene positivo incluso a 60 minutos, aunque con una magnitud decreciente.

- **Consistencia entre arquitecturas.** La estructura espacial de los mapas (zonas de mayor y menor error) es muy similar entre MLP, LSTM, BiLSTM, CNN LSTM y Transformer. Esto indica que, dado el conjunto de variables disponibles, los modelos están explotando esencialmente la misma información y que el límite práctico de predicción está ligado al comportamiento físico de la nubosidad más que al tipo específico de red neuronal.

Modelos satelitales y de fusión

En esta sección se evalúa el aporte de la información satelital de GOES-16 al pronóstico de GHI. Se consideran dos tipos de modelos:

1. **Modelos solo satélite**, que utilizan exclusivamente secuencias de imágenes: ConvLSTM sobre el producto DSRF y CNN LSTM sobre el producto multicanal MCMIPF.
2. **Modelos híbridos satélite + tabular**, que combinan una rama de imágenes (DSRF o MCMIPF) con una rama tabular alimentada por las mediciones locales de superficie y variables derivadas.

Métricas de desempeño global

La Tabla 4 resume los resultados para los modelos basados en los productos satelitales DSRF y MCMIPF, así como sus contrapartes híbridas que integran información tabular local.

Cuadro 4: Desempeño de modelos satelitales y de fusión para $H = 60$ min en el conjunto de prueba.


Modelo	RMSE	MAE	R2	Skill
DSRF ConvLSTM	169.2	96.0	0.569	0.138
DSRF Fusión	139.4	70.0	0.707	0.290
MCMIPF CNN LSTM	156.5	84.0	0.633	0.207
MCMIPF Fusión	136.3	69.4	0.721	0.309

En primer lugar, todos los modelos satelitales superan a la persistencia: el ConvLSTM con DSRF reduce el RMSE en torno a un 14 % y el CNN LSTM con MCMIPF alcanza una mejora cercana al 20 %. Esto confirma que la información satelital contiene señal útil sobre la dinámica de nubes a escala horaria, incluso sin acceder a mediciones locales de planta.


Sin embargo, los errores de los modelos “solo satélite” siguen siendo claramente superiores a los mejores modelos tabulares. Por ejemplo, el RMSE del DSRF ConvLSTM (169.2 W/m^2) es alrededor de un 25 % mayor que el del MLP tabular (135 W/m^2), y el MCMIPF CNN LSTM (156.5 W/m^2) también queda rezagado frente al MLP.

Modelos solo satélite

Las Figuras 16 y 17 sintetizan el comportamiento de los modelos que usan únicamente imágenes satelitales. Cada figura combina la serie temporal de prueba y el diagrama de dispersión GHI observado vs. pronosticado.




(a) Serie temporal en el conjunto de prueba.




(b) GHI observado vs. GHI pronosticado.

Figura 16: Desempeño del modelo ConvLSTM solo DSRF en el conjunto de prueba.



(a) Serie temporal en el conjunto de prueba.



(b) GHI observado vs. GHI pronosticado.

Figura 17: Desempeño del modelo CNN LSTM solo MCMIPF en el conjunto de prueba.

En ambos casos la nube de puntos se concentra alrededor de la diagonal, señal de que el satélite captura una fracción relevante de la variabilidad de la irradiancia. No obstante, la dispersión es mayor que en el caso del MLP tabular y se observan colas más largas asociadas a episodios de nubosidad variable.

Las Figuras 18 y 19 ilustran la estructura de los residuales, evidenciando que los mayores errores se concentran en rangos intermedios de GHI, coherente con un régimen de nubosidad parcial.




Figura 18: Residuales del modelo ConvLSTM solo DSRF.




Figura 19: Residuales del modelo CNN LSTM solo MCMIPF.

Finalmente, los patrones de skill horario (Figuras 20 y 21) son análogos a los observados en los modelos tabulares: skill cercano a cero o negativo durante la noche y positivo durante las horas solares, aunque con magnitud inferior a la del MLP.




Figura 20: Skill horario frente a persistencia del modelo ConvLSTM solo DSRF.





Figura 21: Skill horario frente a persistencia del modelo CNN LSTM solo MCMIPF.

Modelos híbridos satélite + tabular


Los modelos de fusión integran explícitamente una rama satelital (DSRF o MCMIPF) con una rama tabular temporal. La Tabla 4 muestra que:

- En DSRF, la fusión reduce el RMSE de 169.2 a 139.4 W/m² y eleva el skill de 0.14 a 0.29.
- En MCMIPF, la fusión reduce el RMSE de 156.5 a 136.3 W/m² y aumenta el skill de 0.21 a 0.31, alcanzando valores prácticamente idénticos a los del MLP tabular.

Las Figuras 22 y 23 muestran la serie temporal y el diagrama de dispersión de los modelos híbridos. En ambos casos la nube de puntos se contrae alrededor de la diagonal en comparación con sus contrapartes solo imagen, y se reduce la amplitud de los errores en picos de irradiancia.




(a) Serie temporal en el conjunto de prueba.




(b) GHI observado vs. GHI pronosticado.

Figura 22: Desempeño del modelo de fusión DSRF + tabular en el conjunto de prueba.



(a) Serie temporal en el conjunto de prueba.



(b) GHI observado vs. GHI pronosticado.

Figura 23: Desempeño del modelo de fusión MCMIPF + tabular en el conjunto de prueba.

Los residuales (Figuras 24 y 25) muestran una clara reducción de la varianza frente a los modelos solo satélite, con menos errores extremos en los rangos intermedios de irradiancia. Esto indica que la rama tabular aporta información local de corto plazo que los parches satelitales no pueden capturar por sí solos.




Figura 24: Residuales del modelo de fusión DSRF + tabular.




Figura 25: Residuales del modelo de fusión MCMIPF + tabular.

En términos de skill horario, la Figura 26 muestra que los modelos híbridos dominan a la persistencia en prácticamente todas las horas solares y que, en el caso de MCMIPF, el skill se acerca a los valores del MLP tabular para la mayor parte del día.




Figura 26: Skill horario frente a persistencia para los modelos híbridos satélite + tabular.

En síntesis, los modelos solo satélite son capaces de explotar la estructura espacial de la nubosidad pero, sin información local, no alcanzan el nivel de precisión de los modelos tabulares. La fusión satélite + tabular combina lo mejor de ambos mundos: el contexto espacial de GOES-16 y la señal puntual de la planta, logrando métricas globales equivalentes o superiores al mejor modelo puramente tabular en el caso de MCMIPF.

Resumen

Los resultados permiten extraer tres conclusiones cuantitativas centrales:

1. **Bajo un esquema puramente tabular, el MLP ofrece el mejor desempeño global.** Reduce el RMSE en torno a un 31 % frente a la persistencia y alcanza el mayor skill (0.31) y R^2 (0.73) entre los modelos basados únicamente en datos de superficie. Las arquitecturas secuenciales mejoran también de forma clara al baseline, pero no superan al MLP, lo que sugiere que la información temporal relevante ya está codificada en las características construidas.
2. **Los modelos solo satélite capturan parte importante de la variabilidad, pero no son suficientes para igualar a los modelos tabulares.** Tanto el ConvLSTM

con DSRF como el CNN LSTM con MCMIPF logran skill positivo y reducen el RMSE frente a la persistencia (entre 14 y 20 %), pero mantienen errores absolutos mayores que el MLP tabular. El producto MCMIPF se muestra sistemáticamente superior a DSRF en este esquema.

3. **La fusión satélite + tabular mejora sistemáticamente el desempeño y lleva a los modelos híbridos al nivel del mejor modelo puramente tabular.** En DSRF, la fusión reduce el RMSE en aproximadamente 18 % frente al modelo solo imagen y casi duplica el skill. En MCMIPF, la fusión reduce el RMSE en torno a 13 % y produce un modelo cuyo desempeño es prácticamente indistinguible del MLP, con skill ligeramente superior al resto de modelos secuenciales.

En conjunto, los resultados sostienen la hipótesis de que:

- La información local de planta, bien explotada mediante modelos tabulares, define una línea base fuerte para horizontes de 60 minutos.
- La información satelital de GOES-16 añade valor principalmente cuando se integra de forma explícita con esa línea base, más que cuando se emplea de manera aislada.
- El beneficio marginal de la fusión es mayor para el producto multicanal MCMIPF que para el producto derivado DSRF, lo que apunta a la importancia de preservar la riqueza espectral y espacial de las observaciones satelitales.

Los aspectos físicos, operativos y de costo computacional asociados a estas conclusiones se discuten en detalle en el siguiente capítulo.

Discusión

Los resultados obtenidos muestran un comportamiento coherente con la naturaleza física del problema y con las limitaciones inherentes de cada tipo de fuente de información. En conjunto, permiten entender no sólo qué modelos funcionan mejor, sino también por qué lo hacen, en qué regímenes atmosféricos se expresan sus ventajas relativas y hasta qué punto la información satelital añade valor cuando se integra con datos de superficie.

Desempeño de los modelos tabulares

Los modelos tabulares constituyen una línea base fuerte para el horizonte de 60 minutos. La Tabla 2 muestra que el MLP alcanza un RMSE cercano a 135 W/m^2 y un *skill* de aproximadamente 0.31 frente a la persistencia, mientras que las arquitecturas secuenciales (LSTM, BiLSTM, CNN-LSTM y Transformer) se agrupan en un rango muy similar de desempeño, sin superar al MLP de manera sistemática.

La razón principal es que las mediciones locales de superficie capturan la señal de mayor fidelidad disponible en el punto de estudio: la irradiancia responde a variaciones de nubosidad, estabilidad térmica y contenido de humedad que se reflejan directamente en GHI, temperatura, viento y presión. La combinación de geometría solar, índice de cielo despejado, retardos y estadísticas móviles introduce suficiente estructura temporal como para que un MLP, aun sin memoria explícita, logre aproximar la dinámica relevante para el horizonte de 60 minutos.

El hecho de que las arquitecturas recurrentes no superen al MLP sugiere que, bajo el esquema de características utilizado, buena parte de la información temporal relevante ya está incorporada en las entradas. El modelado secuencial aporta mejoras marginales en algunos intervalos horarios, pero no genera una brecha clara de desempeño global. Para este horizonte concreto, el beneficio de introducir memoria explícita parece ser menor que el aporte de una ingeniería de características tabular cuidadosa.

Estructura del error, skill y horizonte de pronóstico

Los mapas hora - horizonte de RMSE y *skill* para los distintos modelos tabulares muestran patrones muy consistentes entre arquitecturas. El RMSE tiende a:

- Aumentar con el horizonte de pronóstico, como es de esperar en un sistema atmosférico con memoria finita y variabilidad convectiva.

- Alcanzar sus valores más altos alrededor del mediodía solar, cuando la irradiancia absoluta es mayor y pequeños errores relativos se traducen en diferencias grandes en W/m^2 .

En contraste, el *skill* frente a la persistencia revela que:

- La mejora relativa de los modelos es máxima en horas solares intermedias (aprox. 9:00–15:00), donde la variabilidad nubosa es marcada y la persistencia se vuelve un *baseline* frágil.
- El *skill* se aproxima a cero o incluso se vuelve ligeramente negativo en horas nocturnas, donde la irradiancia real es cercana a cero y la persistencia reproduce casi perfectamente la trayectoria del objetivo.

Esta estructura, prácticamente idéntica entre MLP, LSTM, BiLSTM, CNN–LSTM y Transformer, indica que el límite práctico de predictibilidad está más impuesto por el fenómeno físico (turbulencia, convección, organización de nubes) que por diferencias sutiles en capacidad de las arquitecturas. La función de los modelos, en este contexto, es acercarse tanto como sea posible a ese límite, más que superarlo mediante incrementos marginales de complejidad.

Aporte de los modelos satelitales puros

Los modelos basados exclusivamente en imágenes satelitales (ConvLSTM sobre DSRF y CNN–LSTM sobre MCMIPF) ofrecen una perspectiva complementaria. Sus resultados muestran dos rasgos clave:

- La información espacial de GOES–16 es capaz de capturar patrones organizados de nubosidad, desplazamiento aparente y gradientes de radiación en el entorno de Bogotá.
- Sin embargo, al carecer de anclaje local, su error global sigue siendo mayor que el de los mejores modelos tabulares, en particular en regímenes de irradiancia intermedia.

El ConvLSTM entrenado únicamente con DSRF logra un *skill* positivo frente a la persistencia, pero con RMSE notablemente superior al MLP tabular. Esto es coherente con el hecho de que DSRF es un producto derivado por transferencia radiativa: incorpora supuestos físicos y modelos intermedios que introducen incertidumbre adicional respecto a una medición directa de GHI.

El CNN–LSTM sobre MCMIPF, al preservar la riqueza multicanal del ABI, mejora parcialmente este panorama: su *skill* frente a la persistencia es mayor que el de DSRF ConvLSTM y sus residuales presentan menos sesgo sistemático. No obstante, el modelo satelital puro sigue sin alcanzar los niveles de error de los mejores modelos tabulares, especialmente en ventanas de nubosidad variable rápida donde la serie local contiene detalles que el satélite, por su resolución espacial y naturaleza remota, no puede reconstruir completamente.

En términos de estructura del error, los modelos satelitales tienden a:

- Funcionan razonablemente bien en condiciones de cielo muy despejado o muy nublado, donde la firma espacial es clara y estable.
- Mostrar errores mayores en rangos intermedios de GHI, típicos de nubosidad parcial y transiciones rápidas, donde faltan pistas locales de alta frecuencia.

Modelos de fusión multifuente

Los modelos híbridos de fusión constituyen el punto de encuentro entre ambos mundos: la señal puntual de superficie y el contexto espacial satelital. La comparación cuantitativa en la Tabla 4 muestra que:

- Para DSRF, la fusión reduce el RMSE frente al modelo ConvLSTM puro y aumenta el *skill* frente a la persistencia, acercando su desempeño al de los mejores modelos tabulares.
- Para MCMIPF, la arquitectura de fusión alcanza un RMSE y un *skill* prácticamente indistinguibles de los del MLP, e incluso los supera ligeramente en ciertos intervalos horarios y rangos de irradiancia.

El análisis de residuales y gráficos de *skill* por hora sugiere que la fusión mejora especialmente en:

- Regímenes de irradiancia intermedia, donde los modelos solo satélite cometen errores grandes y los modelos puramente tabulares subestiman algunas transiciones de nubosidad.
- Horas del mediodía y primeras horas de la tarde, cuando la combinación de geometría solar, convección y desarrollo de nubosidad hace el problema más desafiante.

Desde una perspectiva conceptual, la rama tabular actúa como anclaje local de alta resolución temporal, mientras que la rama satelital aporta información espacial sobre el entorno que el sensor de superficie no puede ver. La concatenación de ambos embeddings en los modelos híbridos permite reducir la incertidumbre asociada a situaciones donde la misma GHI local puede corresponder a configuraciones nubosas muy distintas en el entorno.

En conjunto, los resultados indican que la información satelital, usada aisladamente, no compite con un modelo tabular bien diseñado. Pero, integrada de forma explícita en una arquitectura de fusión, sí aporta mejoras medibles y coherentes con la física del problema.

Implicaciones operativas y de modelado

Desde un punto de vista operativo, los resultados sugieren varias implicaciones:

- Para un horizonte de 60 minutos en un entorno tropical andino como Bogotá, un modelo tabular cuidadosamente diseñado (como el MLP propuesto) ofrece un compromiso muy competitivo entre complejidad y desempeño.
- La integración con GOES-16 es especialmente útil cuando el sistema requiere robustez frente a episodios de nubosidad variable, donde la sola información local puede ser insuficiente para anticipar rampas pronunciadas.
- El costo adicional de incorporar imágenes (almacenamiento, preprocesamiento, entrenamiento) sólo se justifica si el objetivo incluye reducir errores en esos regímenes difíciles o si se desea construir una arquitectura reutilizable para otros sitios donde la señal satelital pueda ser más dominante.

Limitaciones y alcances del estudio

Los resultados presentados deben interpretarse dentro de un conjunto específico de condiciones de dominio, datos y diseño de modelos. En particular, el hecho de que los modelos puramente tabulares y los modelos de fusión alcancen el mejor desempeño global no implica que la información de GOES-16 sea intrínsecamente inferior o prescindible, sino que, bajo el contexto considerado, la combinación de mediciones locales y satélite explotada en este trabajo aún está lejos de agotar todas las posibilidades de la información remota.

En primer lugar, el **dominio geográfico** está restringido a una única estación en Bogotá, con un clima particular de sabana de alta montaña y patrones de nubosidad fuertemente modulados por la orografía local. Es razonable pensar que en otros contextos geográficos por ejemplo, zonas costeras con sistemas nubosos más organizados a gran escala, o regiones con menor peso de efectos locales la información satelital podría tener un peso relativo mayor e incluso superar a los modelos entrenados exclusivamente con datos de superficie. Las conclusiones sobre la comparación entre enfoques tabulares, satelitales e híbridos no son, por tanto, directamente generalizables a todo el territorio colombiano sin estudios adicionales.

En segundo lugar, la **longitud y diversidad de la serie histórica** suponen una limitación. Aunque el periodo analizado cubre varios años de datos satelitales y de superficie, sigue siendo acotado si se piensa en escalas climáticas o en la caracterización exhaustiva de eventos raros (episodios extremos, temporadas atípicas). Es razonable esperar que, con una serie más extensa y diversa, tanto los modelos tabulares como los híbridos, especialmente los que explotan información satelital multicanal, puedan mejorar su capacidad de generalización.

En cuanto a la **información satelital**, el estudio se centra en dos productos concretos (DSRF y MCMIPF) y en parches de resolución reducida (por ejemplo, 32×32 píxeles). No se exploran estrategias de preprocesamiento más avanzadas, como extracción de índices físicos derivados, máscaras de tipo de nube, proxies de desarrollo convectivo o composición de múltiples alturas de nube. Tampoco se consideran arquitecturas de visión más sofisticadas (U-Net, CNN 3D, transformers espaciales) que podrían explotar mejor la estructura espacio-temporal de las imágenes. En este sentido, las conclusiones sobre el desempeño limitado de los modelos satelitales puros están condicionadas por la combinación específica de producto, resolución, recorte y arquitectura.

Una tercera limitación se relaciona con la **forma de fusión** entre información tabular e imágenes. Los modelos híbridos implementados realizan una fusión relativamente sencilla: embeddings extraídos de las ramas tabular y satelital se concatenan y se proyectan a una salida escalar. Existen esquemas alternativos de integración (atención cruzada entre ramas, gating dinámico según régimen de irradiancia, jerarquías espaciales temporales más profundas) que podrían redistribuir mejor el peso relativo de cada fuente de información y, en consecuencia, mejorar los resultados de la fusión más allá de lo observado aquí.

También existen **restricciones computacionales y de exploración de hiperparámetros**. Tanto los ConvLSTM como las arquitecturas híbridas con imágenes son costosas en términos de GPU, memoria y tiempo de entrenamiento. Esto obliga a limitar el espacio de búsqueda de Optuna, la profundidad de los modelos y la resolución espacial de los parches, así como a trabajar con ventanas temporales y tamaños de lote que mantengan el problema manejable. Es posible que, con recursos computacionales más amplios, resulten competitivas arquitecturas más profundas o esquemas de entrenamiento más ambiciosos (por ejemplo, preentrenamiento satelital general y fine-tuning local para Bogotá).

Finalmente, el estudio se centra en un conjunto concreto de **métricas de error** (RMSE, MAE, R^2 , *skill* frente a persistencia) y en un horizonte operativo fijo. No se evalúa de manera explícita el impacto económico de los errores (costos de desvío, penalizaciones en mercado, valorización de rampas) ni se exploran horizontes más largos que, a priori, podrían ser más sensibles al aporte satelital. En aplicaciones donde se requieran pronósticos a varias horas vista, o en esquemas multi-sitio, la evaluación relativa de los modelos podría cambiar de manera significativa.

En conjunto, estas limitaciones acotan el alcance de las conclusiones: para la estación, periodo, productos satelitales y arquitecturas específicas de este trabajo, los modelos tabulares bien diseñados y los modelos de fusión basados en MCMIPF definen la referencia actual de desempeño, los modelos satelitales puros aportan información relevante pero no logran alcanzar ese nivel de precisión. Sin embargo, la propia estructura del problema sugiere que, al ampliar el dominio geográfico, extender la serie histórica y explorar formas más ricas de procesar y fusionar la información satelital, el rol relativo de GOES-16 podría ser considerablemente más favorable que el observado aquí.

Conclusión

Este trabajo desarrolló y evaluó un conjunto de modelos de predicción intradiaria de la irradiancia global horizontal con horizonte de 60 minutos, integrando datos de superficie, geometría solar e información satelital proveniente de los productos GOES-16 DSRF y MC-MIPF mediante arquitecturas tabulares, secuenciales, satelitales y de fusión multifuente. A partir de los resultados se establecen las siguientes conclusiones principales.

Primero, los modelos tabulares constituyen una línea base sólida y difícil de superar. El MLP, alimentado por un conjunto cuidadosamente diseñado de características meteorológicas, astronómicas y temporales, alcanzó un RMSE de 135 W/m^2 y un *skill* de 0.31, superando tanto a la persistencia como a las arquitecturas LSTM, BiLSTM, CNN-LSTM y Transformer. Esto demuestra que, para un horizonte de 60 minutos, la estructura temporal relevante ya está contenida en las variables derivadas y que la memoria explícita aporta un beneficio marginal.

Segundo, los modelos construidos exclusivamente con información satelital capturan parte significativa de la variabilidad de la irradiancia, especialmente en regímenes de nubosidad organizada, pero no logran igualar la precisión de los modelos tabulares. El ConvLSTM basado en DSRF y el CNN-LSTM basado en MCMIPF alcanzaron mejoras del 14–20 % frente a la persistencia, pero mantuvieron errores absolutos más altos debido a la ausencia de la señal puntual proporcionada por la estación de superficie. MCMIPF, al conservar múltiples canales espectrales, mostró sistemáticamente mejor desempeño que DSRF.

Tercero, los modelos de fusión multifuente lograron integrar de manera efectiva la información local y el contexto espacial satelital. La combinación de MCMIPF con datos tabulares redujo el error global hasta niveles comparables con el MLP y mejoró la estabilidad en situaciones de nubosidad variable, evidenciando que ambas fuentes de información son complementarias. La fusión redujo los residuales extremos y mejoró el *skill* horario en prácticamente todas las horas solares, confirmando su utilidad para anticipar transiciones nubosas.

En síntesis, los resultados validan la hipótesis central del proyecto: la integración multifuente constituye un enfoque robusto para el pronóstico de irradiancia a corto plazo en entornos de alta variabilidad atmosférica. En términos operativos, los modelos híbridos representan un equilibrio entre precisión y costo computacional, y su implementación en sistemas de gestión energética podría aportar beneficios en la planeación intradiaria, la operación de plantas fotovoltaicas y la reducción de desviaciones en mercados eléctricos.

Como líneas futuras de investigación se identifican tres direcciones prometedoras: (i) extender el análisis a horizontes de 120–180 minutos mediante arquitecturas temporales más profundas; (ii) incorporar información espacial con mayor amplitud, incluyendo campos de viento o advección explícita de nubosidad; y (iii) explorar modelos completamente *end-to-end* basados en *Transformers* espaciales o arquitecturas híbridas de visión y secuencias que

aprovechen más eficientemente la estructura multicanal del producto MCMIPF. Estas extensiones permitirían avanzar hacia sistemas de *nowcasting* más precisos, interpretables y generalizables para la operación solar en Colombia.

Referencias

- [1] N. K. M. A. Alrikabi, «Renewable Energy Types», *Journal of Clean Energy Technologies*, págs. 61-64, 2014. DOI: 10.7763/jocet.2014.v2.92
- [2] XM, Operador del Sistema Interconectado Nacional. «En el cuarto trimestre, 37 proyectos de transmisión y 67 de generación ingresaron para fortalecer el Sistema Interconectado Nacional». Comunicado oficial. dirección: <https://www.xm.com.co/noticias/7491-en-el-cuarto-trimestre-37-proyectos-de-transmision-y-67-de-generacion-ingresaron-para>
- [3] Energía Estratégica. «Colombia supera los 2.2 GW solares: ¿Cuáles son las empresas con más capacidad operativa?» Dirección: <https://www.energiaestrategica.com/colombia-supera-los-22-gw-solares-cuales-son-las-empresas-con-mas-capacidad-operativa/#:~:text=Colombia%20super%C3%B3%20los%202%2C2,1a%20cadena%20de%20valor%20fotovoltaica>.
- [4] Ministerio de Minas y Energía de Colombia. «Plan 6GW Plus: del 2 % al 13.87 %, Colombia da un salto histórico hacia las energías limpias». Boletín de prensa. dirección: <https://www.minenergia.gov.co/es/sala-de-prensa/noticias-index/plan-6gw-plus-del-2-al-1387-colombia-da-salto-historico-hacia-energias-limpias/#:~:text=El%20Plan%20tiene%20la%20meta,energ%C3%ADa%20limpia%20en%20su%20matriz>.
- [5] XM, Operador del Sistema Interconectado Nacional. «Informe de Operación del Sistema y Administración del Mercado 2024». Reporte integral de sostenibilidad, operación y mercado. dirección: <https://www.xm.com.co/reporte-integral-de-sostenibilidad-operacion-y-mercado-2024>
- [6] Comisión de Regulación de Energía y Gas (CREG). «Resolución 024 de 1995. Por la cual se reglamentan los aspectos comerciales del mercado mayorista de energía en el Sistema Interconectado nacional, que hacen parte del Reglamento de Operación.» Diario Oficial No. 41.937 del 24 de julio de 1995, visitado 1 de mar. de 2025. dirección: https://gestornormativo.creg.gov.co/gestor/entorno/docs/resolucion_creg_0024_1995.htm
- [7] Comisión de Regulación de Energía y Gas (CREG). «Resolución 060 de 2019. Por la cual se hacen modificaciones y adiciones transitorias al Reglamento de Operación para permitir la conexión y operación de plantas solares fotovoltaicas y eólicas en el SIN y se dictan otras disposiciones.» Diario Oficial No. 51.004 del 4 de julio de 2019, visitado 1 de mar. de 2025. dirección: https://gestornormativo.creg.gov.co/gestor/entorno/docs/resolucion_creg_0060_2019.htm

- [8] M. de Minas y Energía de Colombia. «Decreto 2025-02-28: Programa Colombia Solar y reglamentación para autogeneración en estratos 1, 2 y 3». Consulta: marzo 2025. dirección: https://www.minenergia.gov.co/documents/13280/2025-02-28_Decreto_Colombia_Solar.pdf
- [9] N. Salazar-Pena et al., «Intra-day Solar and Power Forecast for Optimization of Intra-day Market Participation», *arXiv preprint*, 2025. DOI: 10.48550/arXiv.2501.09551 arXiv: 2501.09551 [cs.LG]. dirección: <https://arxiv.org/abs/2501.09551>
- [10] NOAA GOES-R Program, *Advanced Baseline Imager (ABI)*, <https://www.goes-r.gov/spacesegment/abi.html>, Accessed: [November, 2025], 2025.
- [11] NOAA National Centers for Environmental Information (NCEI), *GOES-R Downward Shortwave Radiation: Surface (DSR)*, 2018. DOI: 10.7289/V59P2Z7T dirección: <https://www.ncei.noaa.gov/access/metadata/landing-page/bin/iso?id=gov.noaa.ncdc:C01524>
- [12] NOAA National Centers for Environmental Information (NCEI), *GOES-R Cloud and Moisture Imagery Products (CMIP)*, 2018. DOI: 10.7289/V5D21V3Q dirección: <https://www.ncei.noaa.gov/access/metadata/landing-page/bin/iso?id=gov.noaa.ncdc:C01502>

Anexos

Enlace a repositorio

`https://github.com/EstebanLN/irradiance-fusion-forecast`

Instructivo para la Descarga del Producto GOES – DSRF en AWS

Instructivo para la Descarga del Producto GOES – Downward Shortwave Radiation (Surface) en AWS

Esteban Ladino Nieto
Proyecto de Grado - Ingeniería Mecánica, Universidad de los Andes

15 de octubre de 2025

Introducción

Este documento describe paso a paso cómo implementar, en Amazon Web Services (AWS), un flujo reproducible para descargar y organizar el producto GOES ABI-L2-DSRS (Downward Shortwave Radiation at Surface, irradiancia de onda corta incidente en superficie) desde el programa AWS Open Data. La arquitectura usa S3 como almacenamiento, AWS Lambda para automatizar tareas y Step Functions para orquestación paralela. El resultado es un repositorio en S3 con los archivos NetCDF horarios del GOES listos para análisis posterior.

Los datos de radiación de onda corta utilizados en este estudio corresponden al satélite GOES-19, que reemplazó operacionalmente al GOES-16 como satélite GOES-Este el 4 de abril de 2025, proporcionando cobertura continua para la región de Colombia.

Arquitectura general del sistema

La arquitectura se basa en los siguientes servicios de AWS:

Para todo el proceso se emplean tres servicios:

- **Amazon S3** (Simple Storage Service): almacenamiento de objetos. Aquí residirán los NetCDF descargados ("crudos") y salidas procesadas. Posteriormente se pueden leer con Python (bo-to3, xarray, netCDF4).
- **AWS Lambda**: ejecución de funciones sin servidor y sin administrar máquinas. Se usa para generar las fechas/horas y para copiar desde el bucket público **noaa-goes16** al bucket del proyecto. Escala automáticamente y sólo se cobra por ejecución.
- **AWS Step Functions**: orquestación de flujos. Permite encadenar la generación de fechas y lanzar, en paralelo controlado, una invocación de Lambda por cada hora.

Cada componente se comunica de manera segura mediante roles IAM y políticas de acceso configuradas para garantizar integridad y trazabilidad.

Requisitos previos

- Cuenta estándar de AWS con acceso a S3, Lambda y Step Functions.

- Región recomendada: **us-east-1** (donde está el bucket público noaa-goes16).
- Permisos: AmazonS3FullAccess, AWSLambdaBasicExecutionRole, AWSStepFunctionsFullAccess. (Para producción, usar políticas mínimas necesarias.)

Estructura de datos del GOES en AWS Open Data

Los datos públicos están en `s3://noaa-goes16`. Para los productos ABI L2 la estructura es:

`ABI-L2-///OR_ABI-L2--M6_G16_s<YYYYJJJHHMM...>.nc`

donde YYYY es el año, JJJ el día juliano y HH la hora UTC. Para DSRS el prefijo es ABI-L2-DSRS. Un ejemplo de prefix válido es:

`s3://noaa-goes16/ABI-L2-DSRS/2024/046/17/`

- NOAA Geostationary Operational Environmental Satellites (GOES) 16, 17, 18 & 19
- NOAA Global Forecast System (GFS)

Configuración del bucket S3

1. Ingrese a la consola de S3 y seleccione “Create bucket”.
2. Asigne un nombre, por ejemplo: goes-dsrs-data-esteban.
3. Mantenga la región en us-east-1.
4. Deshabilite el acceso público y habilite la encriptación predeterminada (AES-256).
5. Cree las siguientes carpetas dentro del bucket:
 - `/lambda/` – para almacenar los scripts de las funciones.
 - `/goes/` – para los archivos descargados.
 - `/outputs/` – para los resultados procesados (archivos agregados o compuestos).

Creación del rol IAM

1. Diríjase a IAM → Roles → Create role.
2. Seleccione el tipo de entidad “AWS Service” y elija Lambda.
3. Asocie las políticas: AmazonS3FullAccess y CloudWatchLogsFullAccess.
4. Asigne un nombre al rol: lambda-goes-access-role.

Implementación de funciones Lambda

Se implementarán dos funciones principales: una para generar las fechas/horas deseadas y otra para procesar las descargas desde GOES.

Función 1: Generar fechas y horas

- Nombre sugerido: generate_dates_hours.
- Runtime: Python 3.12.
- Rol asignado: lambdagoesaccessrole.
- Código fuente (adaptado del script generar_fechas_y_horas.txt):

```
import datetime

def lambda_handler(event, context):
    start_date = datetime.date(2024, 2, 16)
    end_date = datetime.date(2024, 2, 22)

    date_list = []
    current_date = start_date

    while current_date <= end_date:
        date_str = current_date.strftime("%Y%m%d")
        date_list.append(date_str)
        current_date += datetime.timedelta(days=1)

    return date_list

import datetime

def lambda_handler(event, context):
    start_datetime = datetime.datetime(2024, 2, 15, 18)
    # Start at midnight (year, month, day, hour)
    end_datetime = datetime.datetime(2024, 2, 15, 22)
    # Exclusive end (year, month, day, hour)

    date_list = []
    current_datetime = start_datetime

    while current_datetime < end_datetime:
        date_str = current_datetime.strftime("%Y%m%d%H")
        date_list.append(date_str)
        current_datetime += datetime.timedelta(hours=1)

    return date_list
```

Función 2: Descarga del producto GOES DSRS

- Nombre sugerido: process_goes_dsrs.
- Runtime: Python 3.12.
- Rol asignado: lambda-goes-access-role.

Esta función se encarga de acceder a los archivos del producto ABI-L2-DSRS (Downward Short-wave Radiation at Surface) almacenados en el bucket público noaa-goes16 y transferirlos al bucket del proyecto.

```
import numpy as np
import datetime
import netCDF4
import boto3
import os
# S3 configuration
INPUT_BUCKET_NAME = "noaa-goes16"
OUTPUT_BUCKET = "felipesanabria-bucket"
s3_resource = boto3.resource('s3')
s3_client = boto3.client('s3')
# File paths
TMP_FILE_NAME = "/tmp/tmp.nc"
TMP_NPZ_NAME = "/tmp/data.npz"
# Image processing configuration
CENTER_X = 2458
CENTER_Y = 2763
CROP_SIZE = 224
RESIZE_TO = 32
CHANNEL_NAMES = [
    'CMI_C01', 'CMI_C02', 'CMI_C03', 'CMI_C04', 'CMI_C05', 'CMI_C06',
    'CMI_C07', 'CMI_C08', 'CMI_C09', 'CMI_C10', 'CMI_C11', 'CMI_C12',
    'CMI_C13', 'CMI_C14', 'CMI_C15', 'CMI_C16'
]
def resize_array(arr, target_size):
    """Downsample a 2D array to (target_size, target_size) using block averaging."""
    h, w = arr.shape
    block_size_x = h // target_size
    block_size_y = w // target_size
    return arr.reshape(target_size, block_size_x, target_size, block_size_y).mean(axis=(1, 3))
def lambda_handler(event, context):
    # event expected format: "YYYYMMDDHH"
    event = str(event)
    date_str, hour_str = event[:8], event[8:]
    date = datetime.datetime.strptime(date_str, "%Y%m%d")
    hour = int(hour_str)
    year = date.year
    jday = date.strftime("%j")
    prefix = f"ABI-L2-MCMIPF/{year}/{jday}/{hour:02d}/"
    timestamps = []
    images = []
    try:
        response = s3_client.list_objects_v2(Bucket=INPUT_BUCKET_NAME, Prefix=prefix)
        contents = response.get('Contents', [])
    except Exception as e:
```

```

return {'statusCode': 500, 'body': f'Error listing objects: {e}'}
for obj in contents:
    key = obj["Key"]
    if not key.endswith(".nc"):
        continue
    try:
        # Download file
        s3_resource.Bucket(INPUT_BUCKET_NAME).download_file(key, TMP_FILE_NAME)
        ds = netCDF4.Dataset(TMP_FILE_NAME, mode="r")
        timestamp_str = ds.time_coverage_start
        timestamp = datetime.datetime.strptime(timestamp_str, "%Y-%m-%dT%H:%M:%S.%fZ")
        timestamps.append(timestamp.strftime("%Y-%m-%d %H:%M:%S"))
        image_stack = []
        for ch in CHANNEL_NAMES:
            arr = ds.variables[ch][:]
            arr = arr[0] if arr.ndim == 3 else arr
            cropped = arr[
                CENTER_X - CROP_SIZE // 2 : CENTER_X + CROP_SIZE // 2,
                CENTER_Y - CROP_SIZE // 2 : CENTER_Y + CROP_SIZE // 2
            ].data
            resized = resize_array(np.nan_to_num(cropped), RESIZE_T0).astype(np.float16)
            image_stack.append(resized)
            image_tensor = np.stack(image_stack) # shape: (16, 32, 32)
            images.append(image_tensor)
        ds.close()
        if os.path.exists(TMP_FILE_NAME):
            os.remove(TMP_FILE_NAME)
        except Exception as e:
            print(f"Error processing {key}: {e}")
            continue
    if not images:
        return {'statusCode': 404, 'body': 'No valid data found for this hour.'}
    images_np = np.stack(images) # shape: (N, 16, 32, 32)
    timestamps_np = np.array(timestamps) # shape: (N,)
    np.savez_compressed(TMP_NPZ_NAME, images=images_np,
                       timestamps=timestamps_np,
                       output_key = f"goes_data/{date.strftime('%Y%m%d')}_{hour_str}.npz")
    s3_resource.Bucket(OUTPUT_BUCKET).upload_file(TMP_NPZ_NAME, output_key)
    return {
        'statusCode': 200,
        'body': f"Saved to s3://{OUTPUT_BUCKET}/{output_key}"
    }

```

Configuración de AWS Step Functions

1. Ingrese a AWS Step Functions y seleccione “Create state machine”.

2. Elija “Author with code snippets”.
3. Pegue la siguiente definición en formato Amazon States Language (JSON):

```
{
  "Comment": "Workflow para descarga de GOES DSRS",
  "StartAt": "GenerarFechas",
  "States": {
    "GenerarFechas": {
      "Type": "Task",
      "Resource": "arn:aws:lambda:REGION:ACCOUNT_ID:function:generate_dates_hours",
      "Next": "DescargarGOES"
    },
    "DescargarGOES": {
      "Type": "Map",
      "InputPath": "$.dates",
      "Iterator": {
        "StartAt": "Procesar",
        "States": {
          "Procesar": {
            "Type": "Task",
            "Resource": "arn:aws:lambda:REGION:ACCOUNT_ID:function:process_goes_dsrs",
            "End": true
          }
        }
      }
    },
    "End": true
  }
}
```

Ejecución del flujo

1. Desde la consola de Step Functions, seleccione “Start execution”.
2. Defina el rango de fechas de interés, por ejemplo:


```
{
    "start_date": "2024-12-01",
    "end_date": "2024-12-02"
  }
```
3. Monitoree la ejecución en tiempo real. Cada fecha se procesa como una rama paralela.
4. Los resultados se almacenan en el bucket goes-dsrs-data-esteban/goes/.

Resultados esperados

- Archivos NetCDF del producto DSRS para cada hora seleccionada.

-
- Cada archivo incluye la variable Downward Shortwave Radiation Flux [W/m²].
 - Los archivos pueden ser posteriormente convertidos o agregados en Python para análisis temporal.
 - Costo estimado del proceso (según AWS Pricing Calculator): **USD 15–50**, dependiendo del rango de fechas y número de ejecuciones paralelas. Para el rango típico de pruebas de una semana (7 días X 24 horas), la ingesta implica ~168 invocaciones de copia S3–S3. En experiencia del laboratorio, el costo total (solicitudes S3 + almacenamiento temporal + Step Functions/Lambda) se mantiene entre **USD 15–50**, dependiendo de la cantidad de horas y del volumen de archivos por hora.

Conclusiones

El flujo implementado en AWS permite descargar datos satelitales de irradiancia superficial del GOES de manera eficiente, reproducible y escalable. Este instructivo constituye la base para documentar el proceso de adquisición de datos y justificar el uso de recursos de cómputo en la nube dentro del presupuesto del proyecto de grado.

Autor: Esteban Ladino Nieto

Asesor: Prof. Andrés González Mancera

Departamento: Ingeniería Mecánica, Universidad de los Andes
